Поисковые модели

Часть 2. Лексический и гибридный поиск, усечение поисковой выдачи, параметры индексации

План лекции

Sparse retrieval

Hybrid retrieval

Усечение и калибровка

Индексы

Квантизация

Sparse retrieval

Лексические представления

Лексический поиск

Текст	Токены	indices / values
q: apple juice	[apple, juice]	indices = [12, 54] values = [1, 1]
d: apple pie and apple juice	[apple, pie, apple, juice]	indices = [12, 54, 91] values = [2, 1, 1]

Словарь: apple = 12, juice = 54, pie = 91
values = частоты токенов

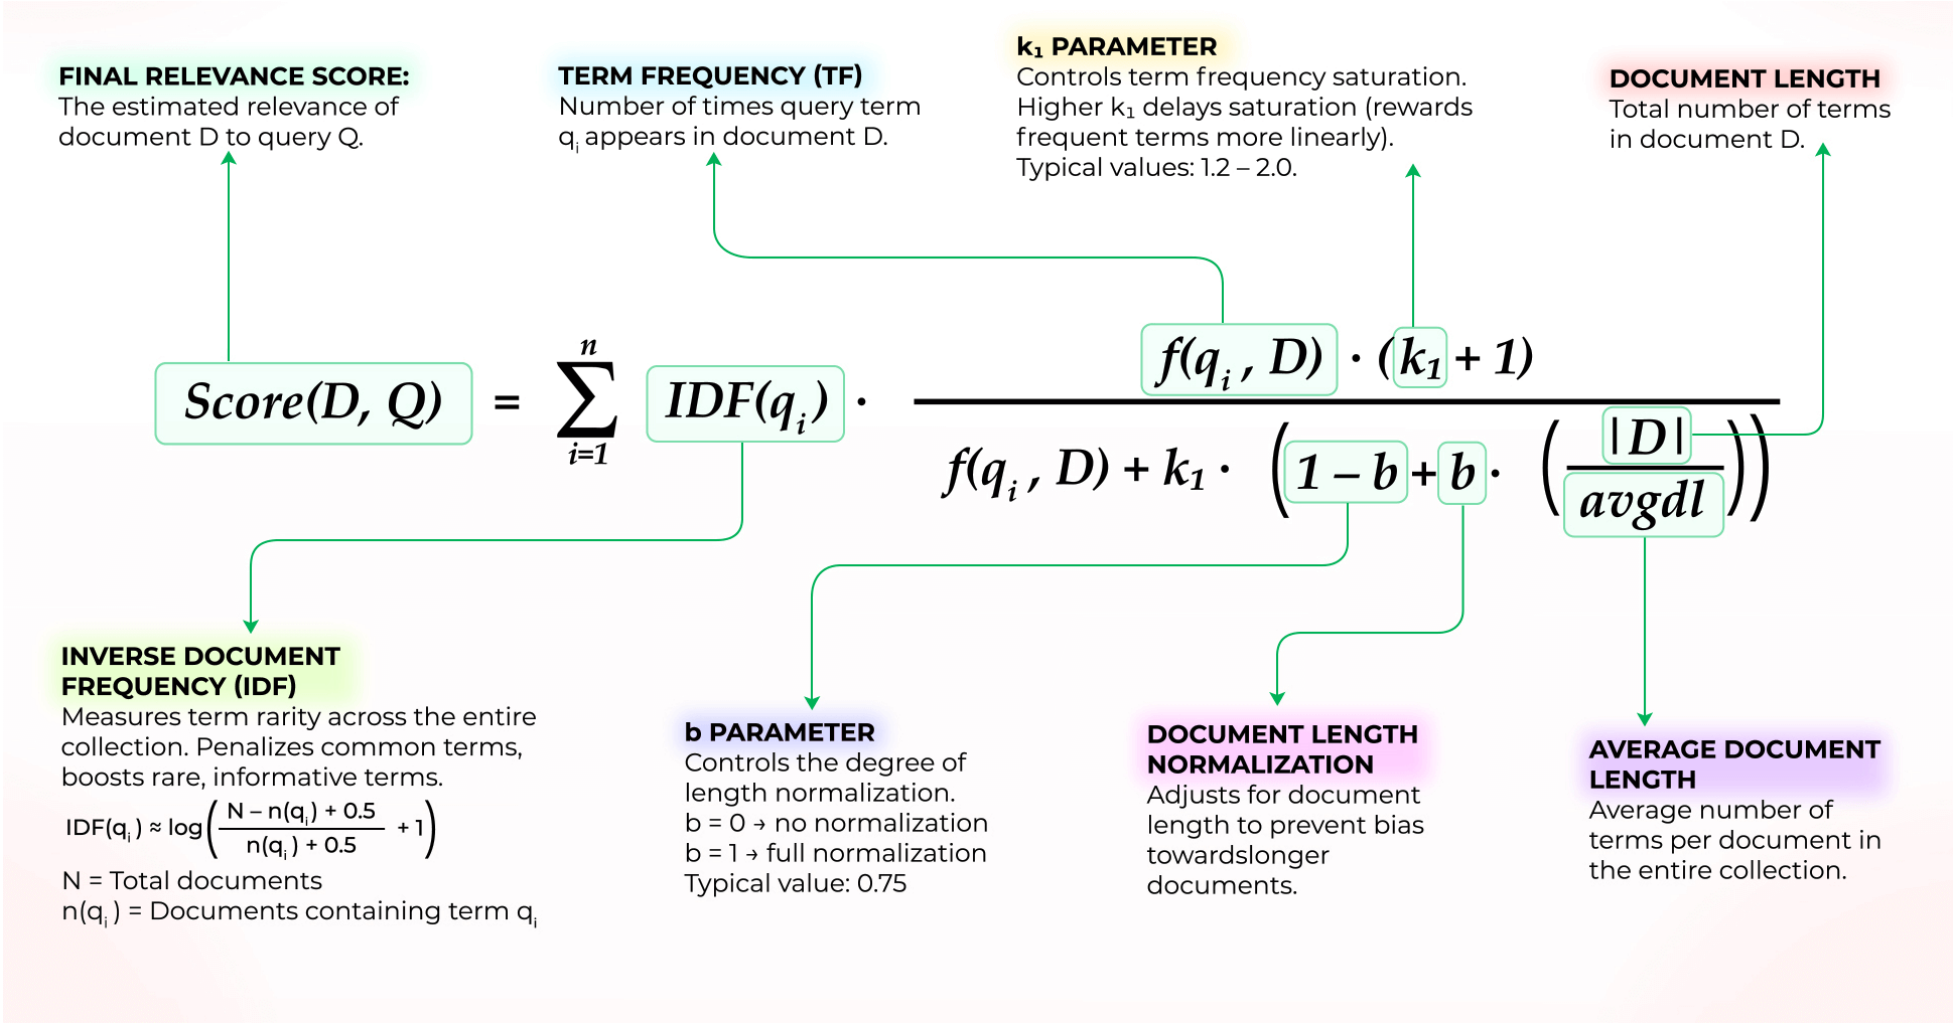
Скалярное произведение sparse-векторов

$$s(q,d) = q^{\top} d = \sum_{j \in I_q \cap I_d} q_j d_j = 1 \cdot 2 + 1 \cdot 1 = 3$$

q, d — векторы запроса и документа
q_j, d_j — веса координаты j
Iq, Id — наборы ненулевых ID
s(q,d) — итоговый скор

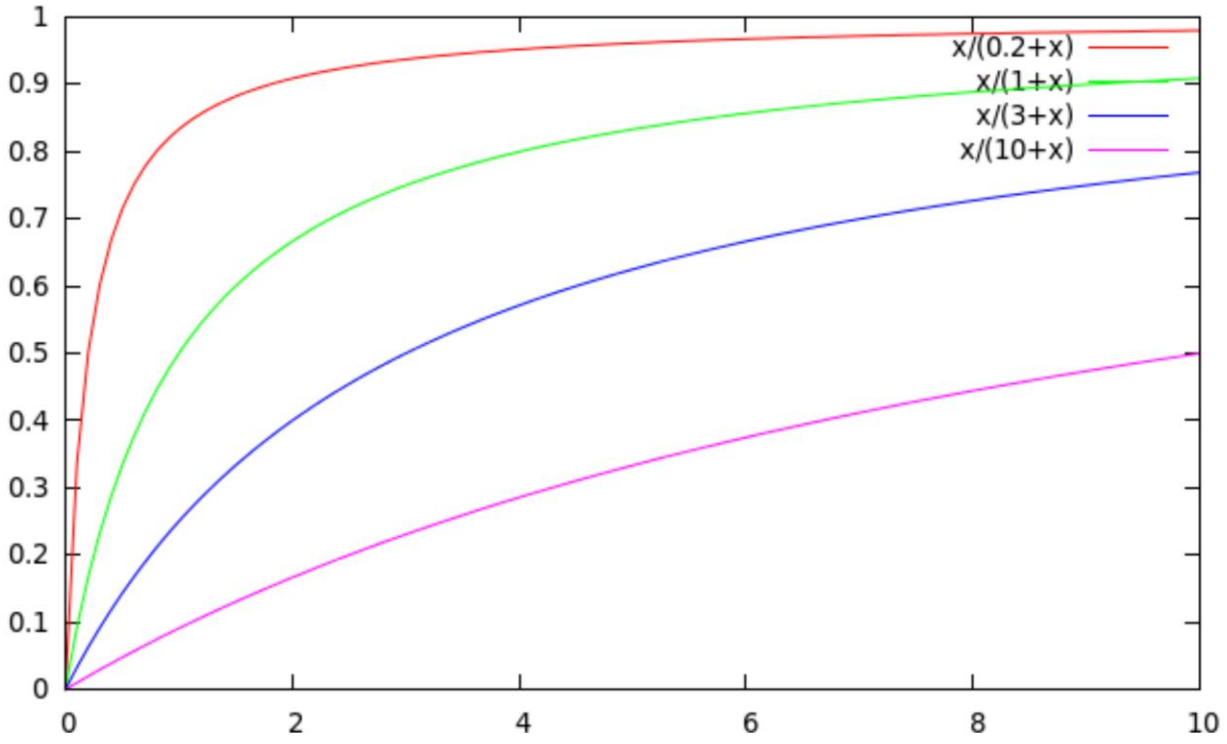
Qdrant · Sparse Vectors and Inverted Indexes

BM25



Manning, Raghavan, Schütze_BM25_https://qdrant.tech/documentation/edge/edge-bm25/

Параметры BM25



Поправка на длину в знаменателе BM25

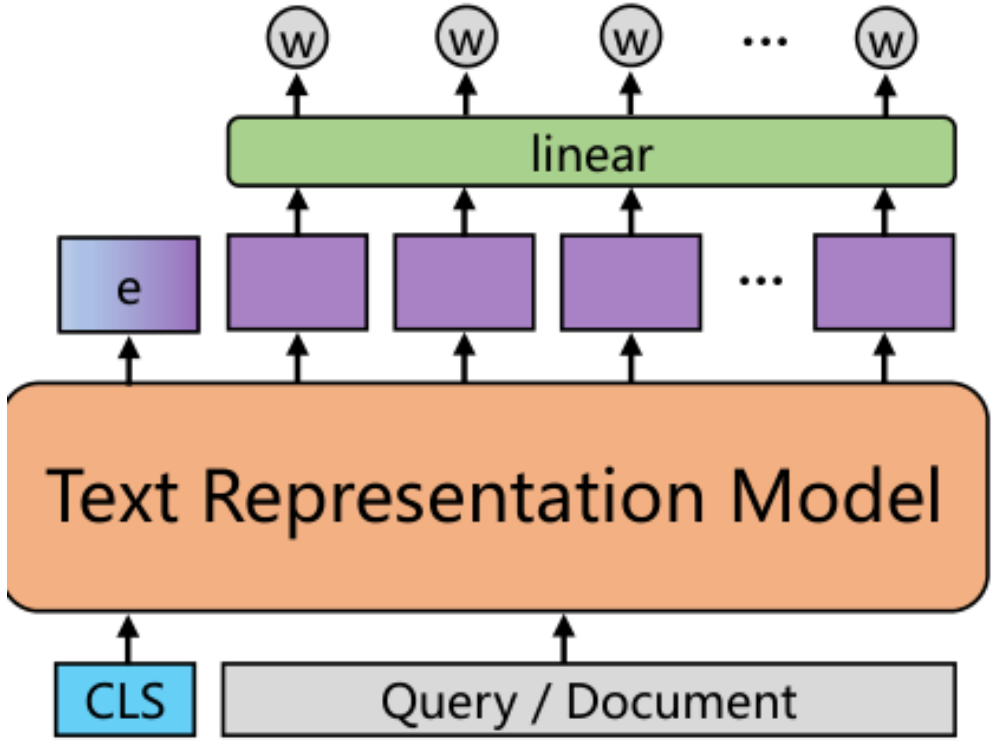
$$b = 0: K(d) = k_1$$

$$b = 1: K(d) = k_1 \frac{|d|}{\text{avgdl}}$$

K(d) — множитель нормировки частоты
|d| — длина d в токенах
avgdl — средняя длина документа
k_1 — насыщение частоты; b — нормировка

На графике слева меняется k_1:
меньшие значения быстрее насыщают вклад повторений термина.

Обучаемые веса



Вес термина: проекция и max-pooling

$$w_i = \mathrm{ReLU}(W h_i)$$
$$w_t(x) = \max_{i:x_i=t} w_i$$

x — входные токены; i — позиция
h_i — контекстный embedding токена x_i
W — обучаемая линейная проекция
w_i — вес позиции; t — token ID
$w_t(x)$ — max среди позиций с ID t

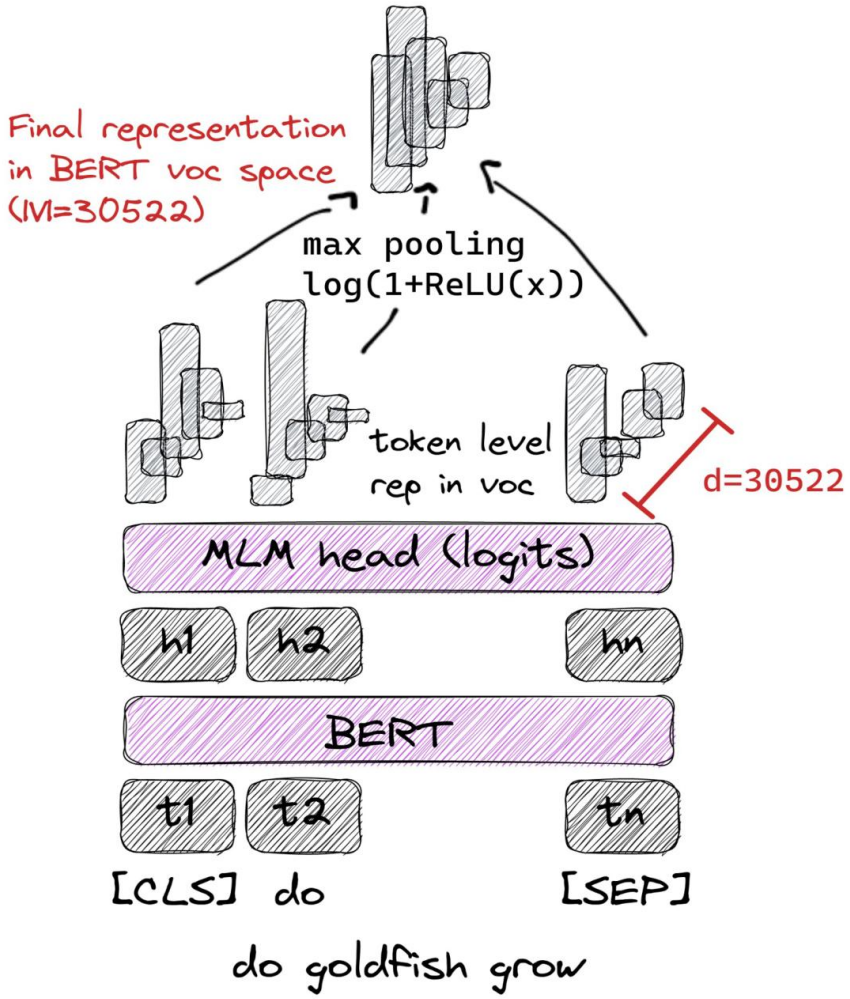
Сходство: скалярное произведение

$$s(q,d) = \sum_{t \in V} w_t(q) w_t(d)$$

q, d — тексты запроса и документа
V — словарь; $w_t(q)$, $w_t(d)$ — веса термина
s(q,d) — итоговый скор поиска

Zhang et al. · mGTE · Fig. 3

SPLADE



Из MLM-logits в вес координаты

$$\phi(z) = \log(1 + \mathrm{ReLU}(z))$$
$$w_v(x) = \max_i \phi(z_{iv})$$

x — входной текст; i — позиция токена
v — термин; z и z_{iv} — logits MLM
ϕ — активация log(1 + ReLU)
$w_v(x)$ — max по всем позициям текста x

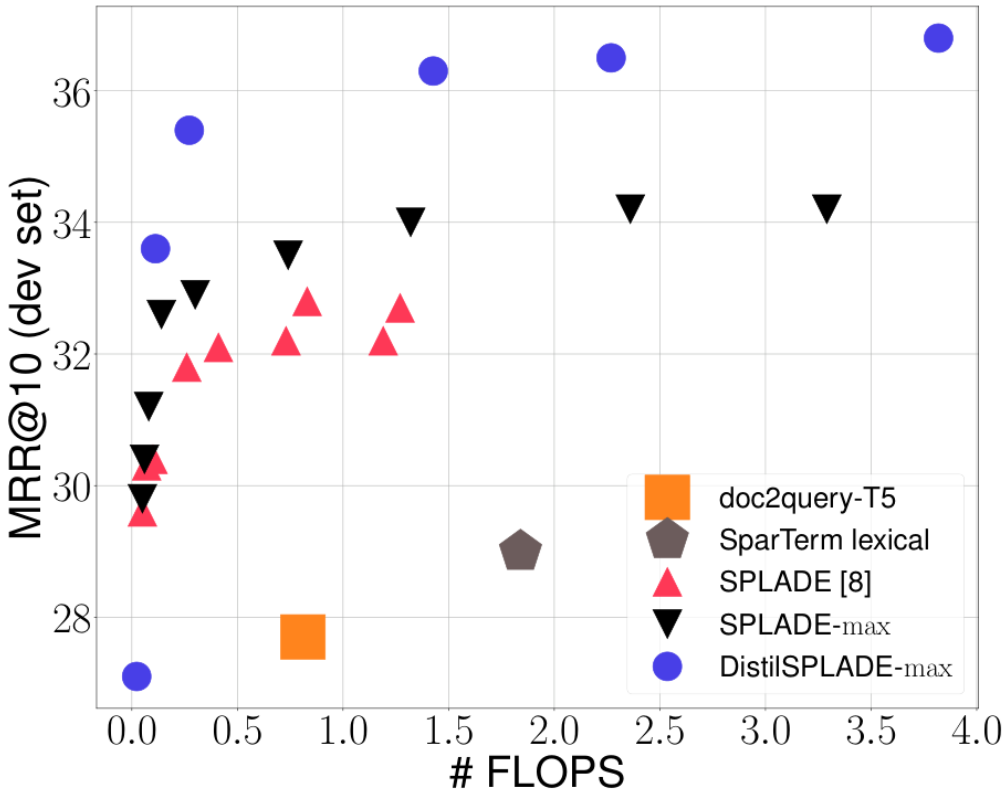
Скалярное произведение весов

$$s(q,d) = \sum_{v \in V} w_v(q) w_v(d)$$

q, d — запрос и документ; V — словарь
$w_v(q)$, $w_v(d)$ — веса термина v
s(q,d) — итоговый скор поиска

Lassance, Clinchant · ReNeuIR 2022 · SPLADE architecture

Разреженность SPLADE



Ошибка поиска и штрафы разреженности

$$\mathcal{L} = \mathcal{L}_{\text{retrieval}} + \lambda_q \mathcal{R}_q + \lambda_d \mathcal{R}_d$$

L — итоговая ошибка обучения
Lretrieval — ошибка ранжирования
Rq, Rd — штрафы за активации sparse-векторов запросов q и документов d
λq, λd — веса соответствующих штрафов

Большие λ сильнее подавляют активации:
реже встречается активный термин,
короче его posting list.

Formal et al. · SPLADE v2 · Fig. 1

Домен и язык

Original	après une réunion de spécialistes durant trois jours en autriche importante réforme de l'orthographe allemande à partir de fin 1995. les experts de ces trois pays ont tenue une conférence de trois jours sur la réforme de l'orthographe de la langue allemande. ils ont décidé que celle-ci pourra être appliquée dès la fin de l'année 1995 et sera contraignante à l'issue d'une période de transition de six ans, à partir de l'an 2001. l'application de la réforme devra être surveillée par une commission sur l'orthographe.
PSQ	year own german important in first be as germany will reform austria written letter 2001 end 1995 conference three experts
SPLADE-X (BI)	aut deutschen allemand language years script year application reform important allemande spelling deutsche grammar transition conference languages ##rap ort phone

BM25: частоты своего домена

IDF подстраивает веса терминов
Лемматизация объединяет формы

SPLADE: общие координаты

Expansion связывает формы и синонимы
SPLADE-X связывает разные языки

Nair et al. · SPLADE-X · Fig. 1

Sparse: сравнение

Метод	Источник сигнала	Где выигрывает	Что стоит учитывать
BM25	IDF своего корпуса без обучения	Терминология домена, новые имена и артикулы	Словоформы сводит стеммер / лемматизатор
mGTE-TRM	Важность токена из контекста	Точные совпадения при разной важности слов	Энкодер на запрос Без новых терминов
SPLADE	MLM расширяет набор координат	Словоформы, синонимы SPLADE-X: разные языки	Энкодер + MLM Более длинные postings

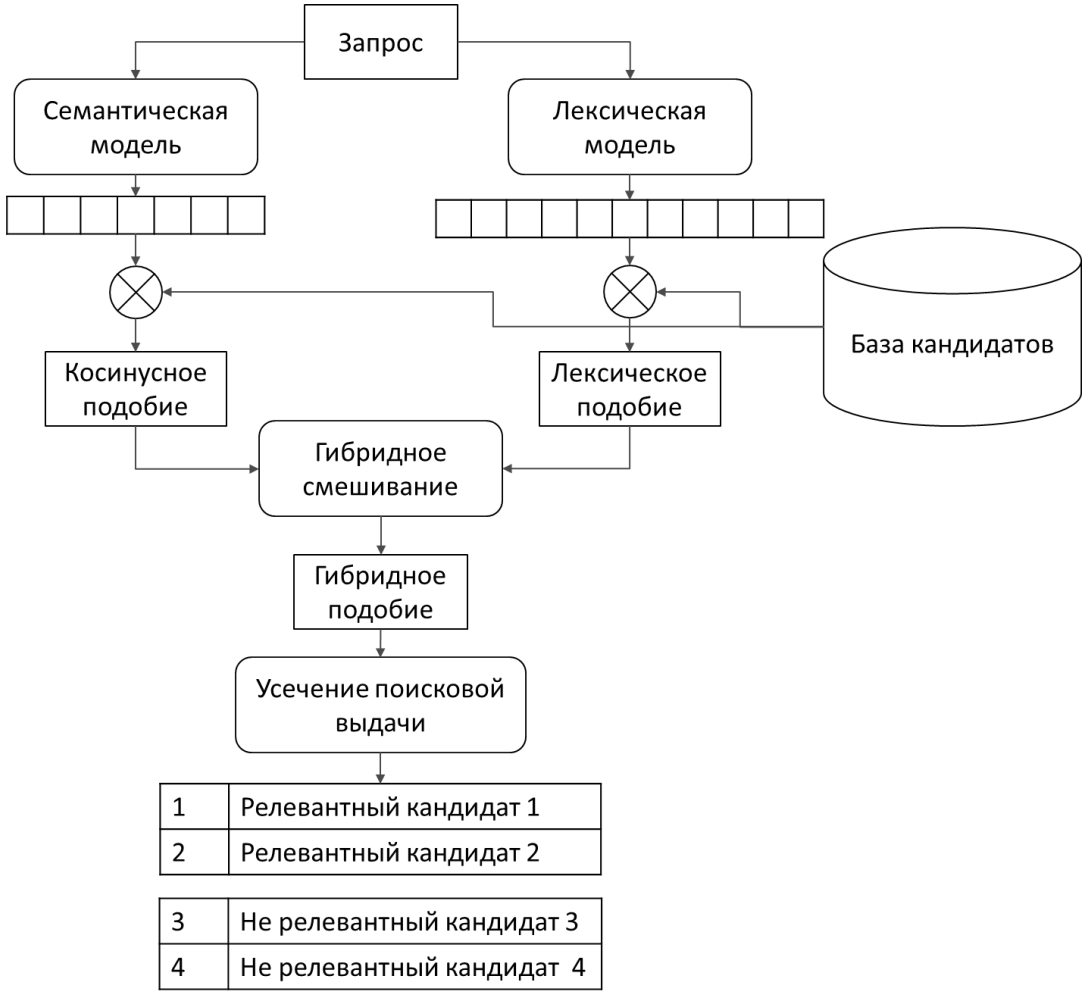
BM25 адаптируется статистикой корпуса. Neural sparse переносит знания модели.

Manning, Raghavan, Schütze · BM25 · Zhang et al. · mGTE · Fig. 3

Hybrid retrieval

Объединение поисковых сигналов

Гибридный поиск



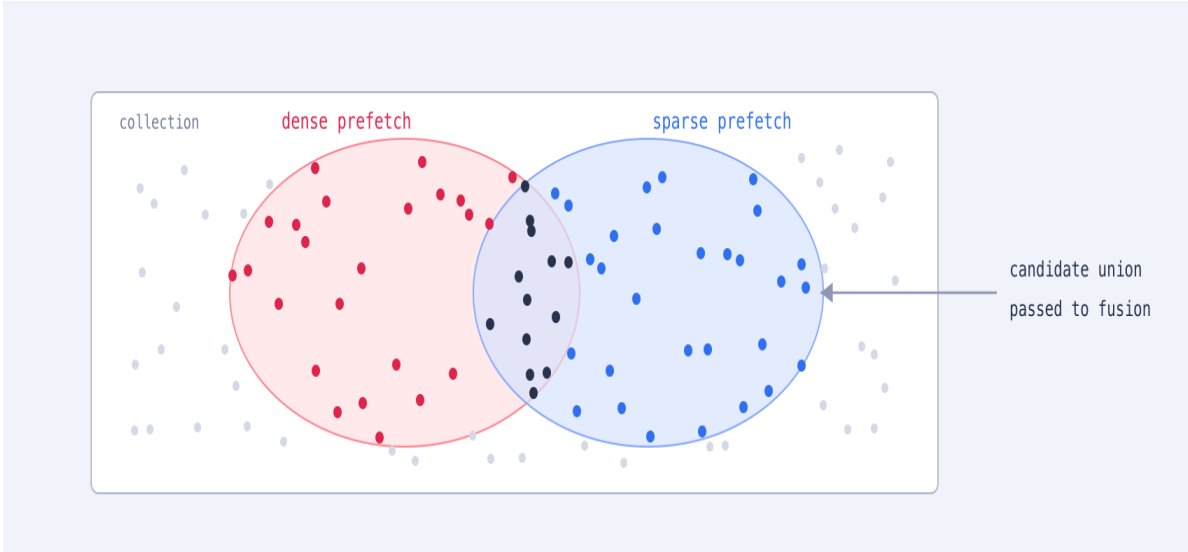
где

$$s_{hybrid} = \alpha \cdot s_{sem} + (1 - \alpha) \cdot s_{lex},$$

s_{sem} – семантическое косинусное подобие

s_{lex} – лексическое подобие

α – коэффициент смешивания



Qdrant · Hybrid Search

RRF



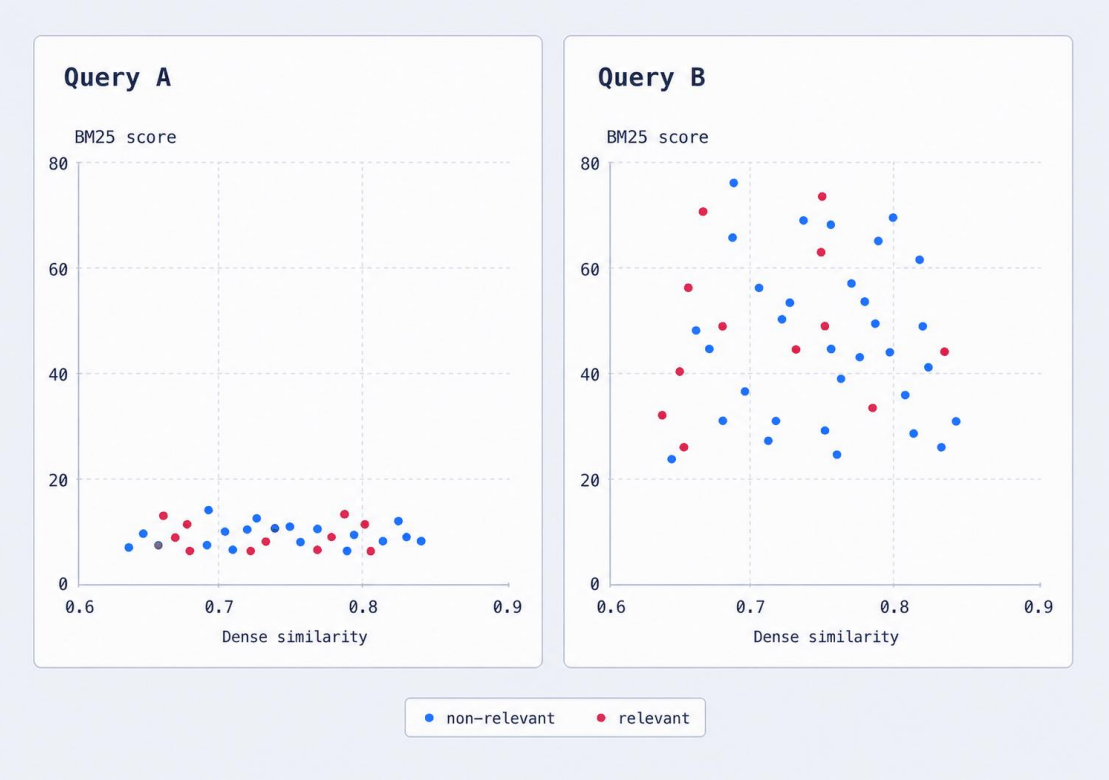
Сумма обратных рангов

$$\mathrm{RRF}(d) = \sum_{j=1}^{J} \frac{1}{c + r_j(d)}$$

d — документ-кандидат
$r_j(d)$ — его ранг в поисковой ветке j
J — число объединяемых веток
c — константа сглаживания
RRF(d) — итоговый гибридный скор

Cormack et al. · SIGIR 2009 · Qdrant · Hybrid Queries

MinMax



Приведение скоров ветки к [0,1]

$$z = \frac{s - s_{\min}}{s_{\max} - s_{\min}}$$

s — исходный скор документа
smin, smax — крайние скоры выдачи ветки
z — нормированный скор этой ветки

Взвешенная сумма dense и sparse

$$s_H = \alpha z_D + (1 - \alpha) z_S$$

zD, zS — нормированные dense / sparse скоры
α ∈ [0,1] — вес dense; 1 − α — вес sparse
sH — итоговый гибридный скор

Qdrant · Hybrid Search · Posokhov et al. · QDAP · Fig. 1

DBSF

DBSF: нормировка по среднему и разбросу

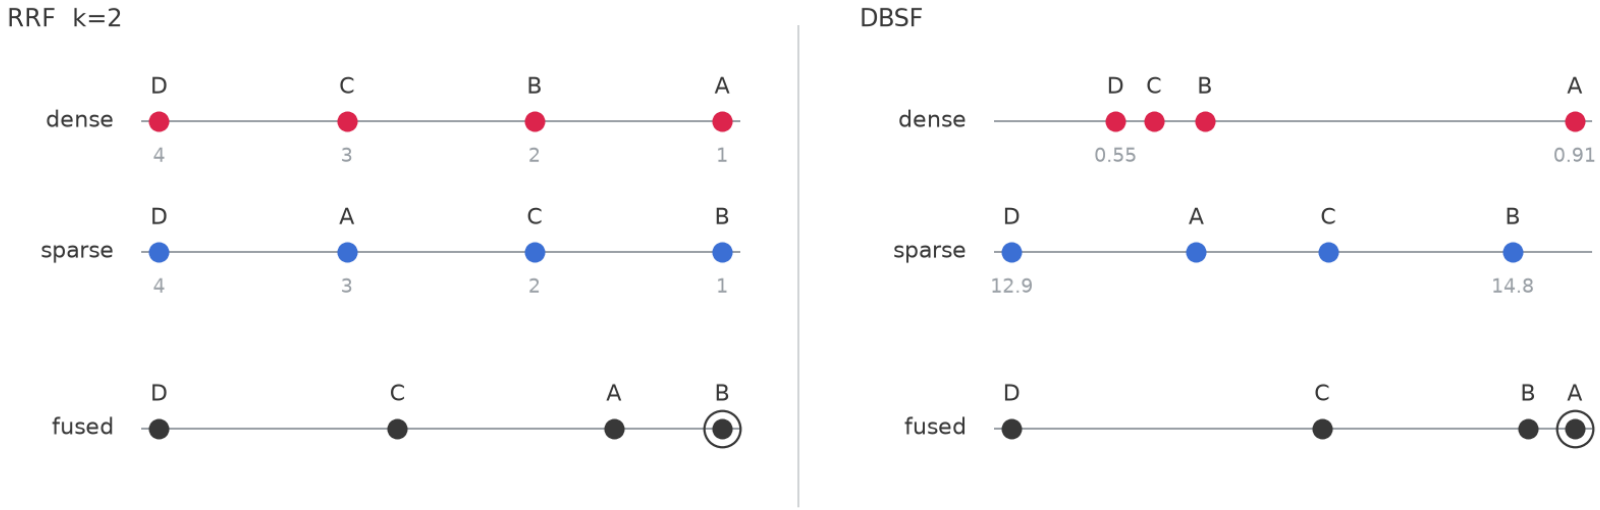
$$z_j(d) = \frac{s_j(d) - \mu_j}{6\sigma_j} + \frac{1}{2}$$

$s_j(d)$ — скор d в ветке j; μ_j — среднее, σ_j — стандартное отклонение
$z_j(d)$ — нормированный скор; статистика считается по выдаче ветки

Сумма нормированных веток

$$s_H(d) = \sum_{j=1}^{J} z_j(d)$$

J — число веток; d — документ
sH(d) — гибридный скор d

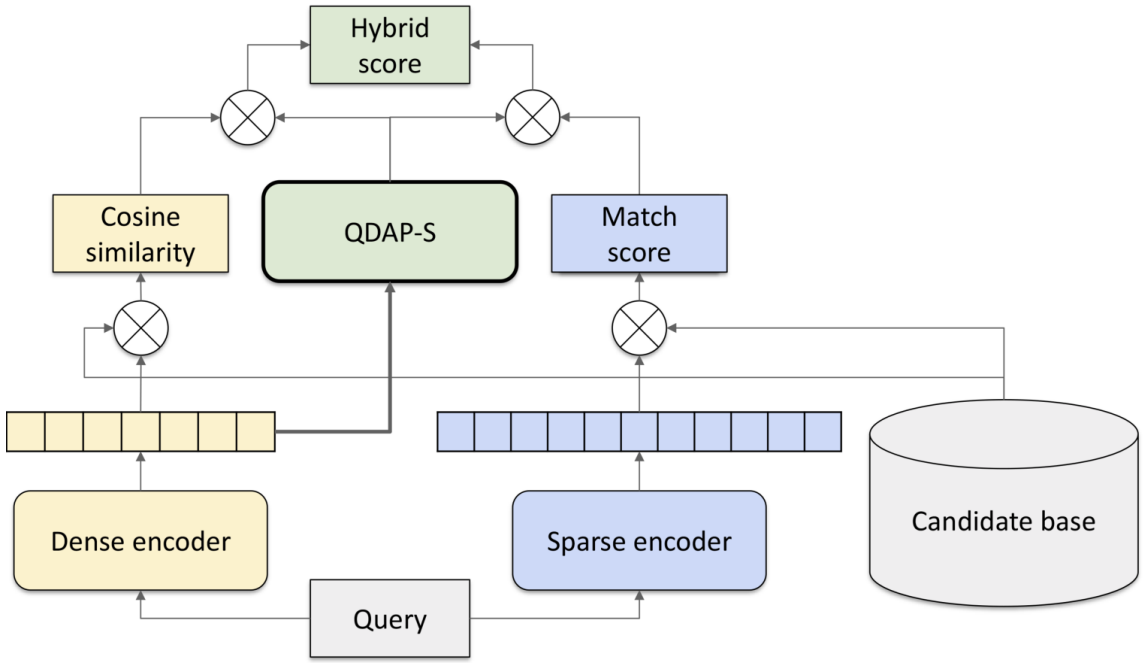


Выбор fusion

Метод	Что сохраняет	Когда выбирать	Цена / слабое место
RRF	Порядок результатов	Разные и нестабильные шкалы веток	Не видит сильный отрыв top-1
MinMax	Разрывы скоров	Баланс α подобран на своих запросах	Масштаб задают крайние скоры
DBSF	Отрыв от среднего	Узкая dense-шкала и широкая BM25-шкала	Выбросы влияют на среднее и разброс

Qdrant · Hybrid Queries · Posokhov et al. · QDAP · Fig. 1

QDAP



Вес dense: ожидание по классам QDAP

$$\alpha(q) = \sum_{i=0}^{100} \frac{i}{100} P_i(q)$$

q — запрос; i/100 — вариант веса dense
$P_i(q)$ — вероятность этого варианта
α(q) — предсказанный вес dense-ветки

Гибридный скор с весом для запроса

$$s_H = \alpha(q) z_D + (1 - \alpha(q)) z_S$$

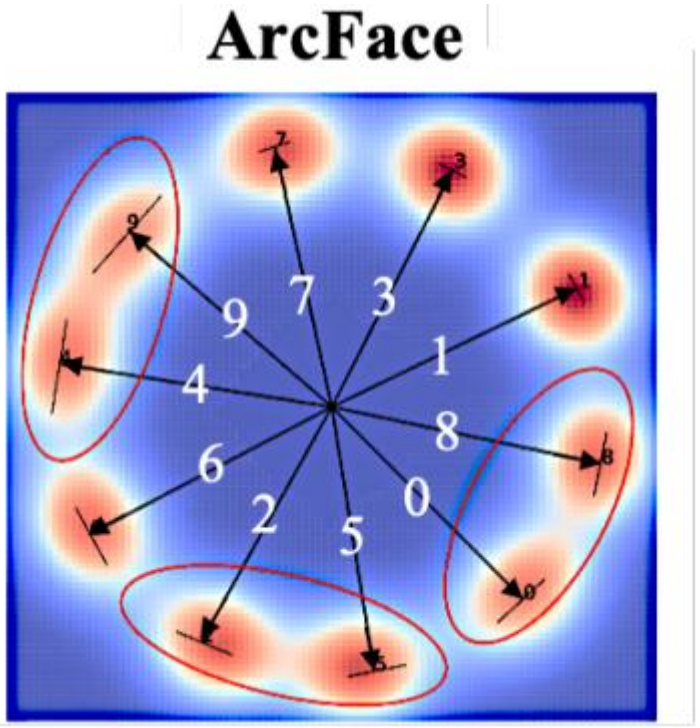
zD, zS — нормированные dense- и sparse-скоры
1 − α(q) — вес sparse-ветки
sH — итоговый скор документа

Posokhov et al. · QDAP · Fig. 1

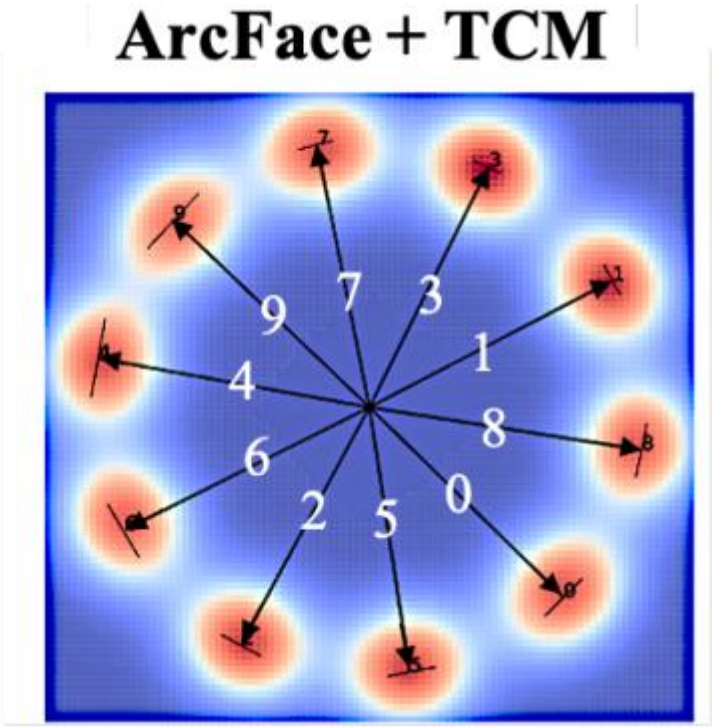
Усечение выдачи

Ранг, порог и калибровка

Ranking и порог

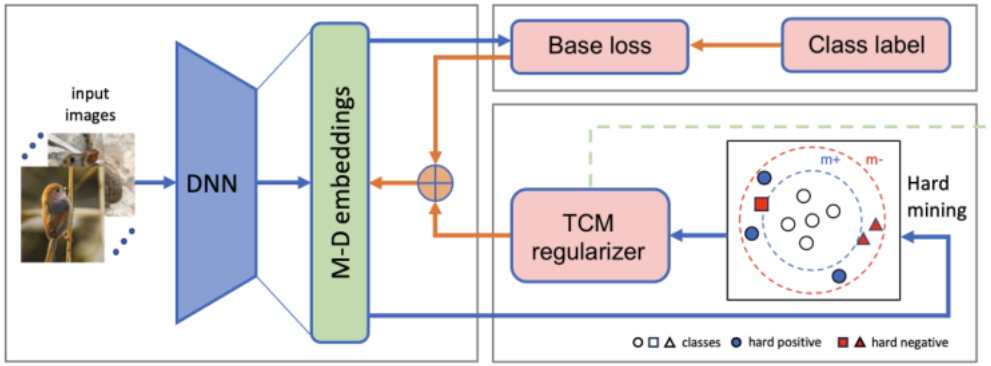


Ranking: какой документ выше



Порог: какой документ оставить

TCM loss



Отбор по порогу сходства

$$s_i = \cos(q, d_i), D^* = \{d_i : s_i \geq \tau\}$$

q, d_i — эмбеддинги запроса и документа
s_i, s — cosine similarity; i — номер документа
τ — общий порог; D* — отобранные документы

TCM: штрафы за нарушение границ

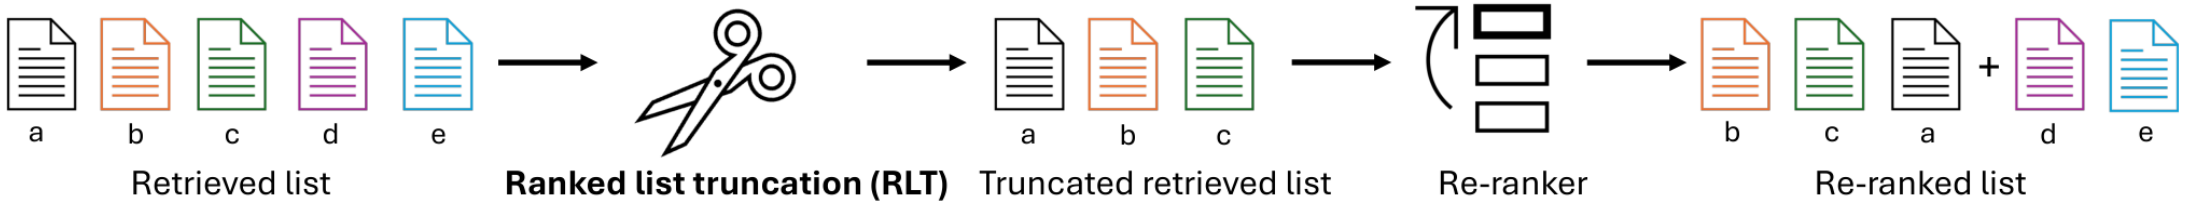
$$\mathcal{L}_+ = \frac{\sum_{s \in H_+}(m_+ - s)}{|H_+|}, \mathcal{L}_- = \frac{\sum_{s \in H_-}(s - m_-)}{|H_-|}$$

$$\mathcal{L} = \mathcal{L}_{\text{rank}} + \lambda_+ \mathcal{L}_+ + \lambda_- \mathcal{L}_-$$

H_+: позитивы $s \leq m_+$; H_-: негативы $s \geq m_-$
L_+, L_- — средние штрафы; $|H\pm|$ — число пар
$m\pm$ — фиксированные границы; $\lambda\pm$ — веса
Lrank — ranking loss; L — суммарная ошибка

Zhang et al. · TCM · ICLR 2024 · Fig. 4(a), Eq. 5–6

Точка усечения



Оптимальная длина выдачи по полезности

$$k^*(q) = \underset{k}{\operatorname{argmax}} U(q,k)$$

q — запрос; k — кандидат на длину выдачи
U(q,k) — полезность первых k документов
k*(q) — длина с максимальной полезностью

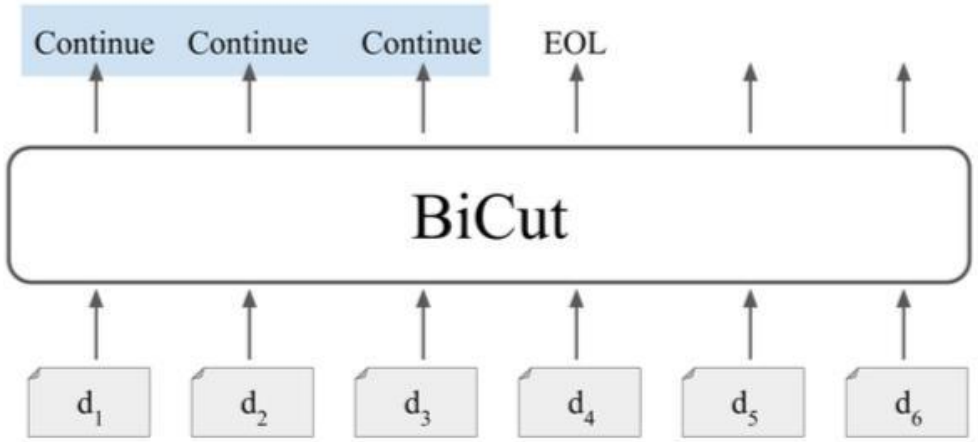
Что включаем в U(q,k)

До reranker: качество после reranking
и затраты на обработку k кандидатов.

В финальной выдаче: релевантность
и объём возвращаемых результатов.

Meng et al. · SIGIR 2024 · Fig. 1

BiCut



Continue и первая точка остановки

$$p_i = P_\theta(\text{Continue} \mid X, i)$$

$$k^* = \min\{i : p_i < \frac{1}{2}\} - 1$$

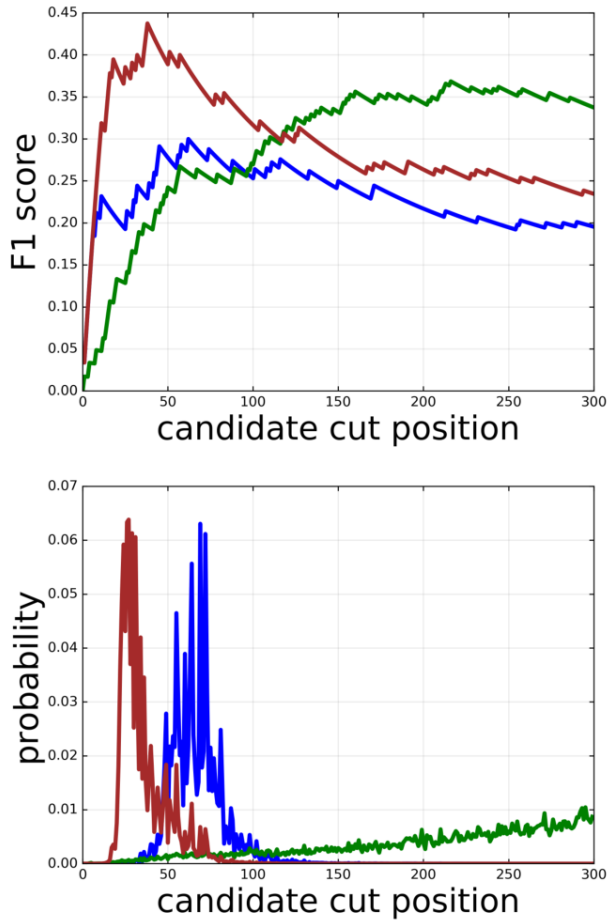
X — признаки n документов; i — позиция
p_i — вероятность Continue в позиции i
θ — параметры BiLSTM + MLP; k* — длина выдачи

Риск ошибочных Continue и Stop

$$\mathcal{L} = \sum_{i=1}^{n} \left[\frac{\alpha(1 - y_i)p_i}{1 - r} + \frac{(1 - \alpha)y_i(1 - p_i)}{r} \right]$$

y_i = 1 — релевантный документ, 0 — нерелевантный
r — доля релевантных документов
α — вес ошибки Continue; 1 − α — ошибки Stop
L — суммарный взвешенный риск

Choppy



Вероятности границ и выбор длины

$$z = \mathrm{Linear}(\mathrm{Transformer}_\theta([S; E]))$$
$$p = \mathrm{softmax}(z), k^* = \underset{k}{\mathrm{argmax}} p_k$$

S — n скоров; E — векторы позиций
z_k — логит границы k; p_k — её вероятность
θ — параметры сети; k* — выбранная длина

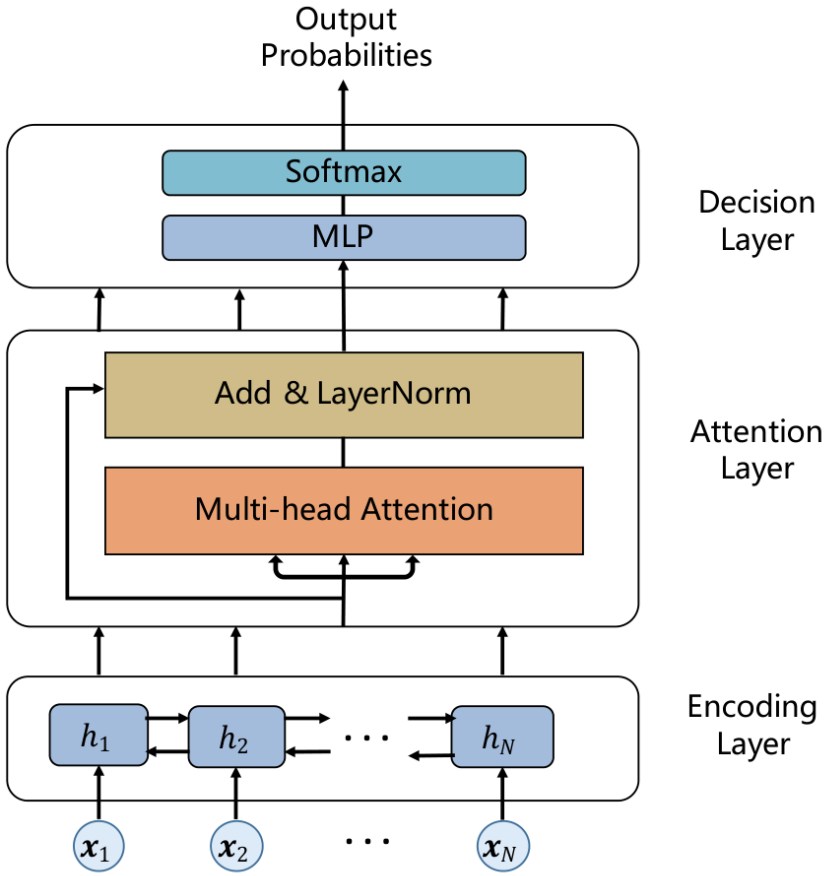
Ошибка: минус ожидаемый F_1

$$\mathcal{L} = -\sum_{k=1}^{n} p_k U(k)$$

k = 1…n — кандидаты на границу списка
U(k) — F_1 первых k документов по разметке
L — ошибка; p_k — вероятность выбрать k

Bahri et al. · Choppy · SIGIR 2020 · Fig. 1

AttnCut



Вероятности границ и выбор длины

$$z = \mathrm{MLP}(\mathrm{Attn}(\mathrm{BiLSTM}_\theta(X)))$$
$$p = \mathrm{softmax}(z), k^* = \underset{k}{\mathrm{argmax}} p_k$$

X — признаки n документов; z_k — логит границы k
p_k — вероятность k; θ — параметры сети
k* — выбранная длина выдачи

Цель: вероятности полезных границ

$$\pi = \mathrm{softmax}\left(\frac{[U(1), \ldots, U(n)]}{T}\right)$$

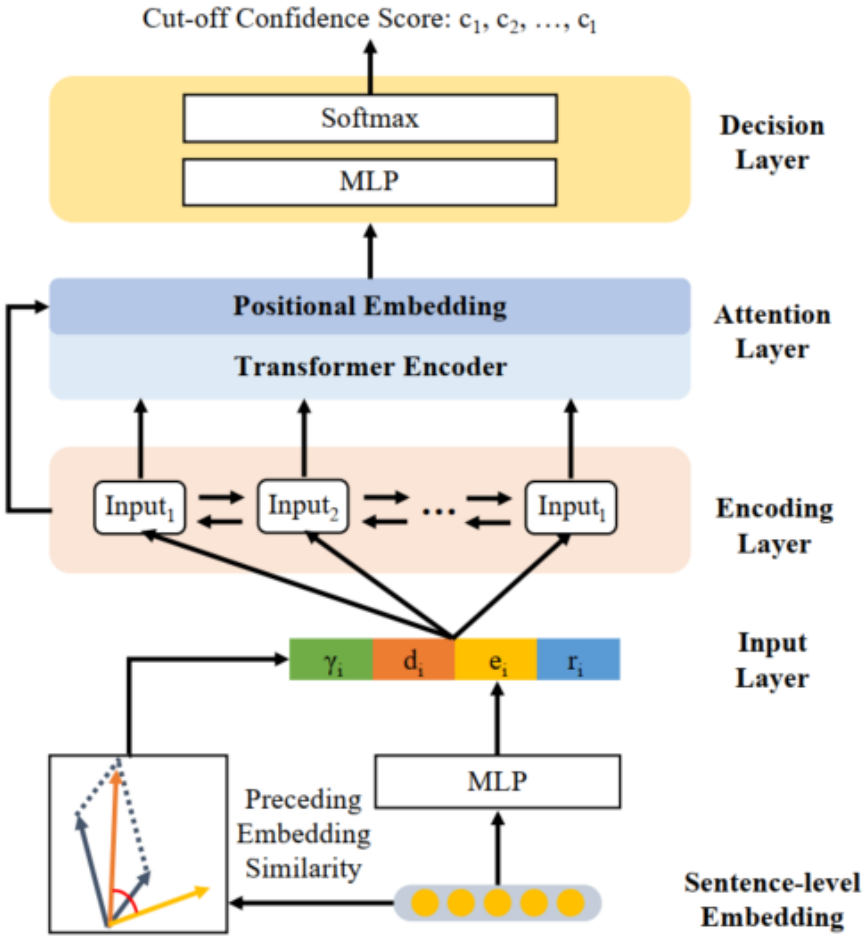
Ошибка RAML: cross entropy

$$\mathcal{L}_{\mathrm{RAML}} = -\sum_{k=1}^{n} \pi_k \log p_k$$

U(k) — F_1 первых k документов; T — температура
π_k — целевая вероятность k; L — ошибка обучения

Wu et al. · AttnCut · AAAI 2021 · Fig. 1, Eq. 3–6

LeCut



Признаки документов и выбор границы

$$x_i = [\gamma_i; d_i; e_i; r_i], e_i = \mathrm{MLP}(h_i)$$
$$p = \mathrm{LeCut}_\theta(x_{1:n}), k^* = \underset{k}{\mathrm{argmax}} p_k$$

r_i — score; d_i — статистика; i — позиция
γ_i — сходство с предыдущими документами
h_i — embedding; e_i — его проекция; x_i — признаки
p_k — вероятность k; n — длина; θ — веса сети
k* — выбранная длина выдачи

Цель: вероятности полезных границ

$$\pi = \mathrm{softmax}\left(\frac{[U(1), \ldots, U(n)]}{T}\right)$$

Ошибка RAML: cross entropy

$$\mathcal{L} = -\sum_{k=1}^{n} \pi_k \log p_k$$

U(k) — F_1 первых k документов; T — температура
π_k — целевая вероятность k; L — ошибка обучения

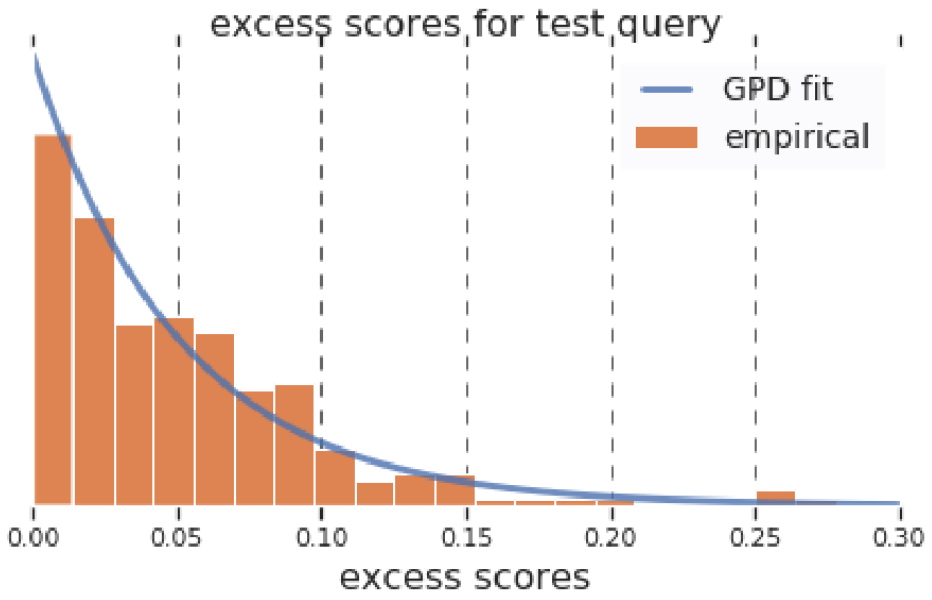
Ma et al. · LeCut · SIGIR 2022 · Fig. 2

Предсказание границы

Метод	Главное отличие	Когда помогает	Цена / следствие
BiCut	Continue / EOL на каждой позиции	Доступны скоры и простые признаки	Ранний EOL отсекает весь хвост
Choppy	Общий выбор k по всему списку	Нужно учить границу под F1, DCG или cost	Максимизирует среднюю полезность
AttnCut	Мягкая цель RAML для разных k	Несколько соседних k почти равноценны	Температура управляет мягкостью цели
LeCut	Семантические признаки retriever	Скоры похожи, смысл документов разный	Нужны embeddings для документов

Meng et al. · SIGIR 2024 · Fig. 1 · Lien et al. · BiCut · ICTIR 2019

Surprise



Surprise: редкость исходного скора

$$e_i = \max(0, s_i - u)$$

$$z_i = -\log\left(1 - G_{\xi,\beta}(e_i)\right)$$

$$D^* = \{d_i : z_i \geq \tau\}$$

s_i — скор документа d_i; u — порог хвоста
e_i — превышение над u; z_i — Surprise
$G_{\xi,\beta}$ — функция распределения Парето
ξ — форма; β — масштаб; τ — порог; D* — результат

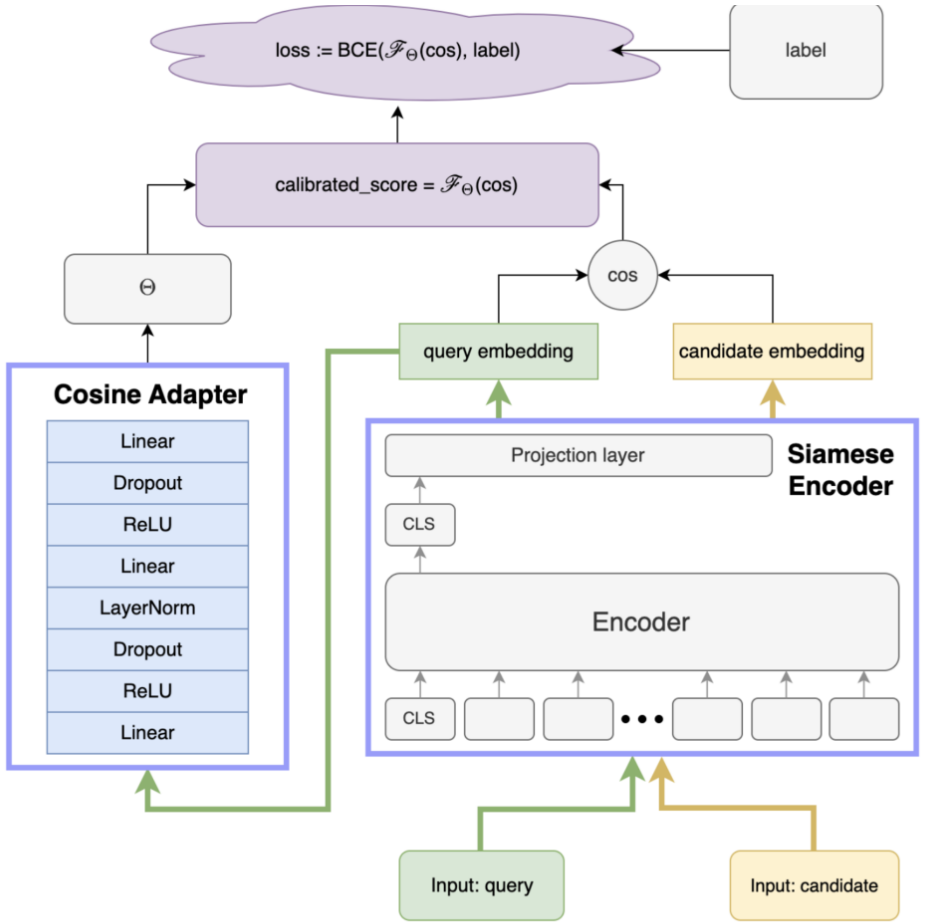
Оценка параметров фонового GPD

$$(\xi^*, \beta^*) = \underset{\xi,\beta}{\operatorname{argmin}} \left[-\sum_{e \in E} \log g_{\xi,\beta}(e) \right]$$

E — превышения фоновых скоров над u
$g_{\xi,\beta}$ — плотность Парето; ξ*, β* — MLE-оценки
Сумма −log g — ошибка подгонки распределения

Bahri et al. · Surprise · Fig. 2, Algorithm 1

Cosine Adapter



Варианты функции калибровки FΘ(x)

$$F_{\text{raw}}(x) = x$$
$$F_{\text{lin}}(x) = ax + b$$
$$F_{\text{sqrt}}(x) = \text{sgn}(x)a\sqrt{|x|} + b$$
$$F_{\text{quad}}(x) = \text{sgn}(x)ax^2 + b$$
$$F_{\text{pow}}(x) = \text{sgn}(x)a|x|^k + b, k \in (0,2)$$

q, d — эмбеддинги; x — их cosine; A — адаптер
Θ = A(q) = (a,b,k): масштаб, сдвиг, степень
t — общий порог; D* — отобранные документы

Отбор по калиброванному скору

$$D^* = \{d : F_\Theta(\cos(q,d)) \geq t\}$$

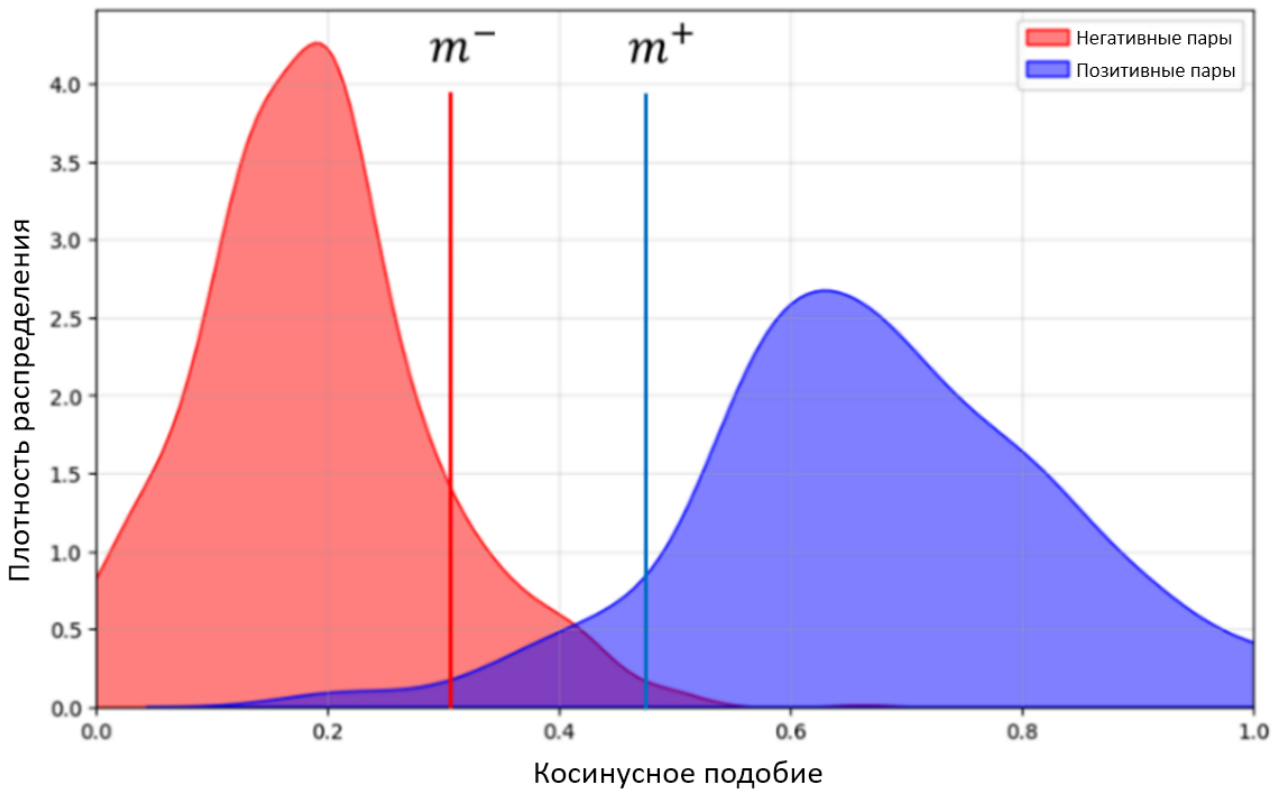
Ошибка релевантности: BCE

$$p_i = \sigma(F_{\Theta_i}(x_i))$$
$$\mathcal{L}_i = -[y_i \log p_i + (1 - y_i)\log(1 - p_i)]$$

$y_i \in \{0,1\}$ — релевантность пары; p_i — вероятность
σ — sigmoid; sgn — знак x; L_i — BCE пары i

Rossi et al. · Cosine Adapter · CIKM 2024 · Fig. 1, Eq. 3–4

TMP Adapter



Функция ошибки с зазором (Threshold Margin Penalty Loss, TMPLoss)

$$TMPloss = BCE + (0{,}5 \cdot P_{pos} + 0{,}5 \cdot P_{neg} - 0{,}2 \cdot R_m), \quad (9)$$

где P_{pos} – штраф за отклонение позитивного кандидата, вычисляемый по формуле 11;

P_{neg} – штраф за отклонение негативного кандидата;

R_m – подкрепление за максимизацию границ зазора;

$$P_{pos} = \frac{\sum_{s \in S^+} \max(0, m^+ - s)}{\sum_{s \in S^+} \begin{cases} 1; s \le m^+ \\ 0; s > m^+ \end{cases}}, \quad (10)$$

где m^+ – граница зазора для позитивных пар S^+.

$$P_{neg} = \frac{\sum_{s \in S^-} \min(0, s - m^-)}{\sum_{s \in S^-} \begin{cases} 1; s > m^- \\ 0; s \le m^- \end{cases}}, \quad (11)$$

где m^- – граница зазора для негативных пар S^-.

$$R_m = m^+ - m^- \quad (12)$$

Выбор калибратора

Метод	Данные	Что исправляет	Когда выбирать
Surprise	Скоры длинной выдачи Метки не нужны	Разную шкалу запросов через модель фона	Новая задача без qrels Есть хвост для оценки
Cosine Adapter	Query embedding и метки пар	Маленькая MLP учит параметры калибровки	Готовый bi-encoder Дешёвый общий порог
TMP Adapter	Query embedding и метки пар	Штрафы и обучаемый зазор между классами	Нужен более стабильный перенос порога

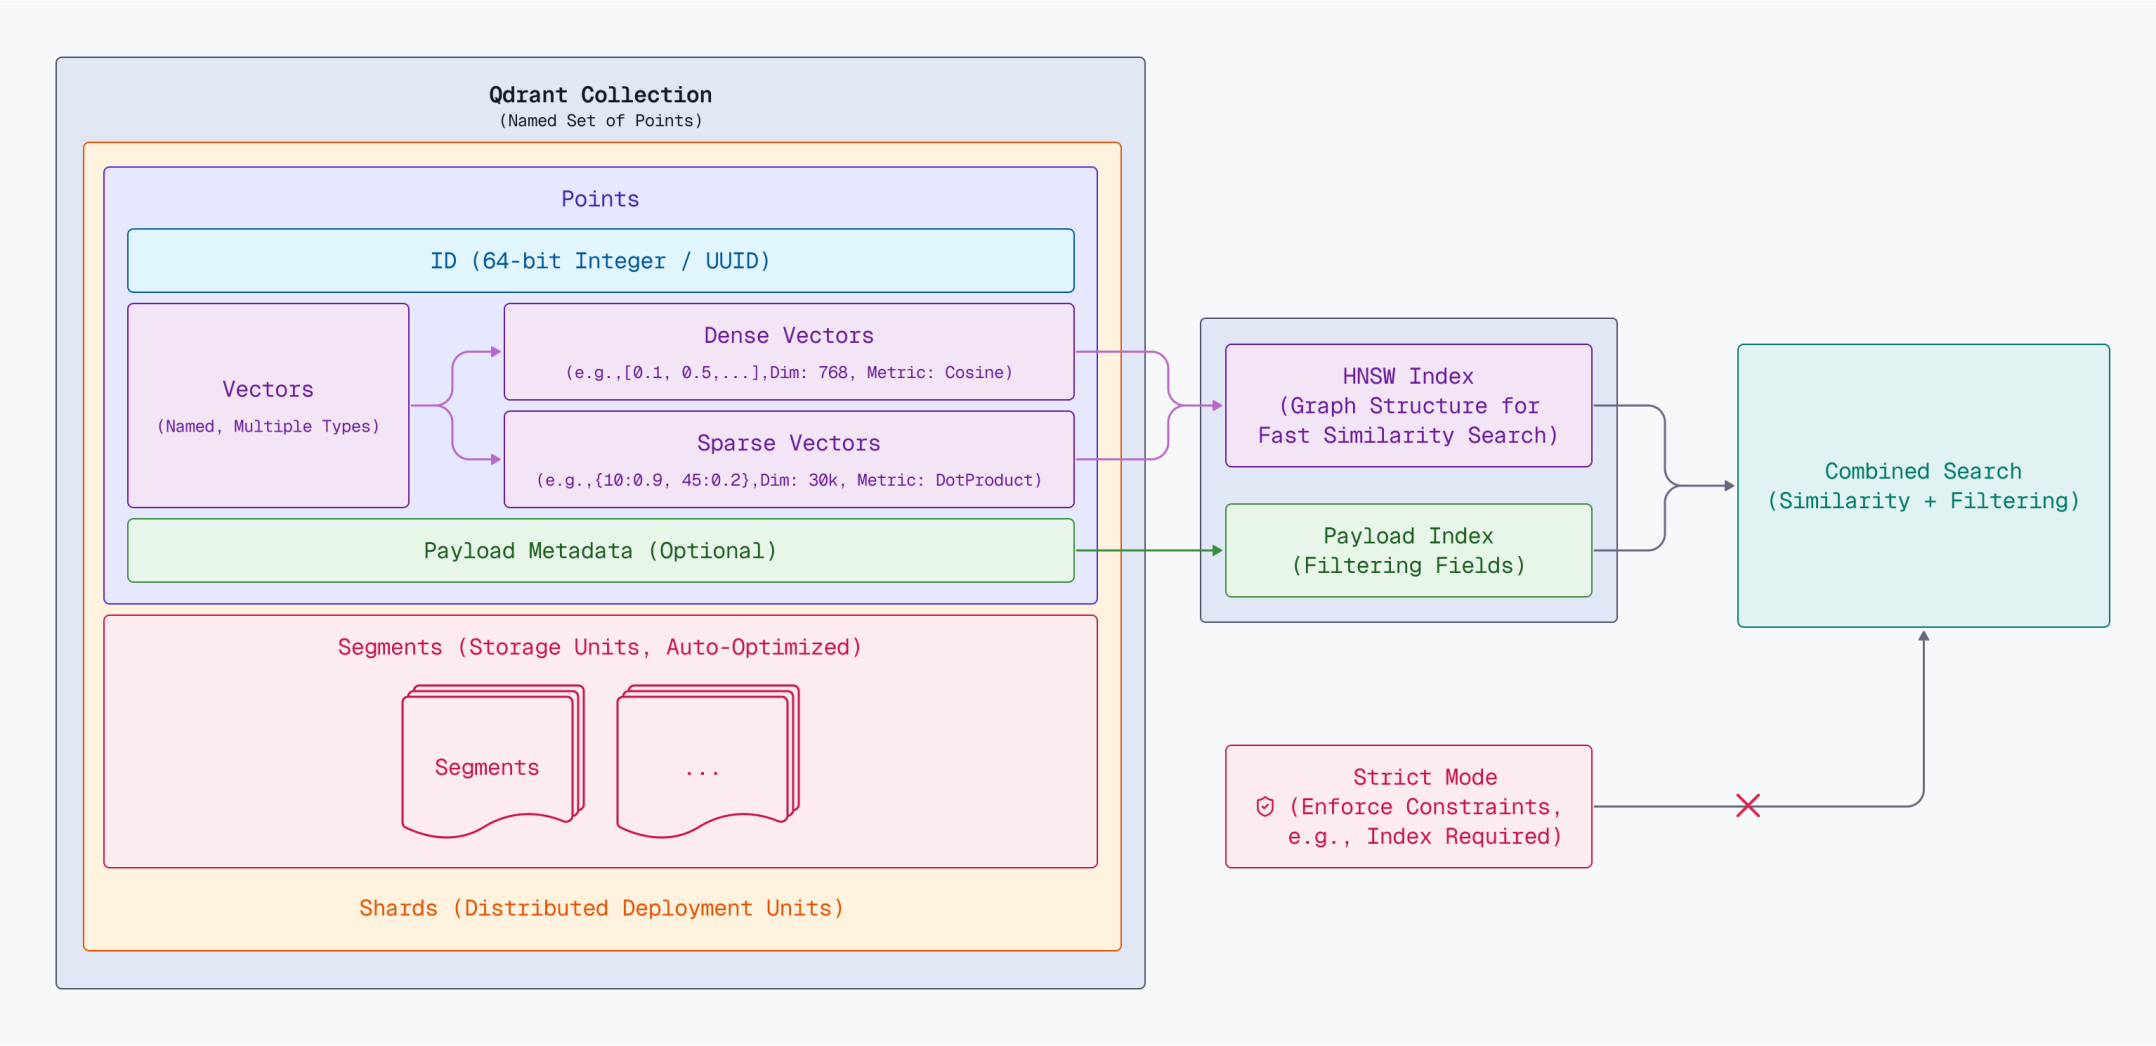
Surprise оценивает фон списка. Адаптеры учатся на релевантности пар.

Bahri et al. · Surprise · Fig. 3 · Rossi et al. · Cosine Adapter · Fig. 1

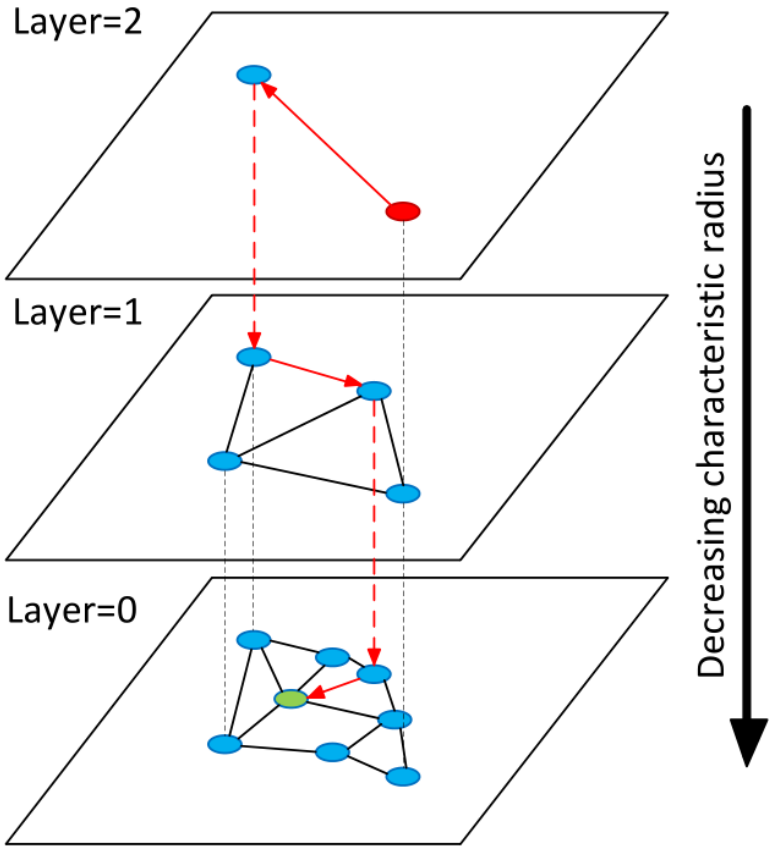
Поисковые индексы

Как получить кандидатов быстро

Поиск в Qdrant



HNSW



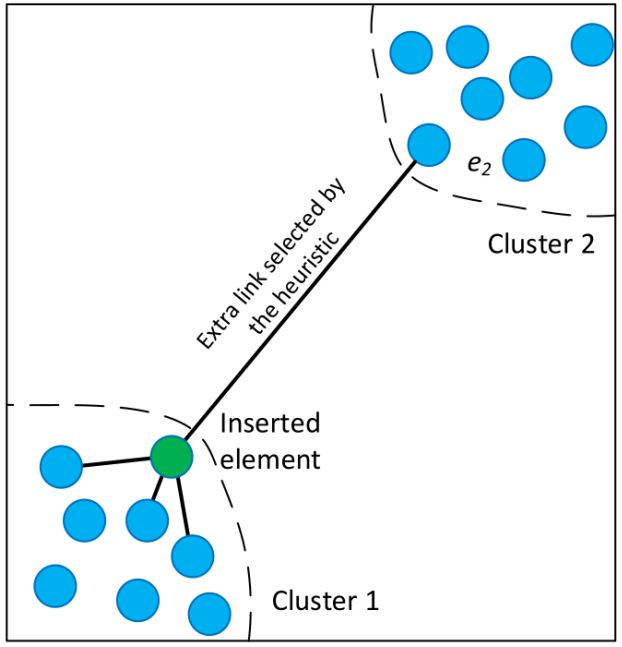
Верхние уровни: навигация

Нижний уровень: детали

Кандидаты уточняются
при движении по графу

Malkov, Yashunin · HNSW · Fig. 1–2

Параметры HNSW

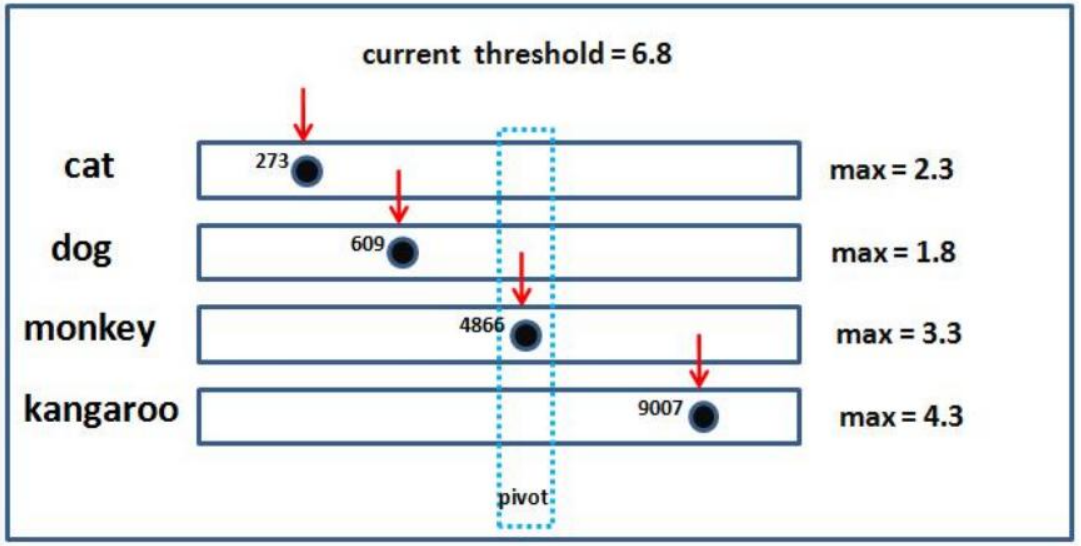


Параметр	За что отвечает
M	Связность и память
ef_construct	Качество построения
hnsw_ef	Ширина поиска

Больше поиска — больше сравнений и выше ANN recall

Malkov, Yashunin · HNSW · Fig. 1–2 · Qdrant · Indexing

Inverted index



Posting list термина t

$$\mathcal{P}(t) = [(d_1, w_1), \ldots, (d_m, w_m)]$$

P(t) — список документов с термином t
d_i — ID документа; w_i — его вес термина
m — длина списка; i — позиция в списке

Накопление скора по терминам запроса

$$s(q,d) = \sum_{t \in q} w_t(q) w_t(d)$$

q, d — запрос и документ; t — token ID
$w_t(q)$, $w_t(d)$ — веса термина t
s(q,d) — итоговый скор документа

WAND и Block-Max

Запрос «кот корм» top-1 Уже найден скор 5

WAND

«кот»		«корм»	
docID	**Вес**	**docID**	**Вес**
→ 3	1	**→ 8**	6
5	2	10	1
8	1,5	12	2
12	1	—	—

→ Текущая запись в каждом списке

doc 3 и doc 5: максимум 2 < 5

doc 8: 1,5 + 6 = 7,5

Block-Max WAND

Остаток каждого списка — отдельный блок

Термин	Записи: docID / вес	Макс.
кот	12 / 1	**1**
корм	10 / 1; 12 / 2	**2**

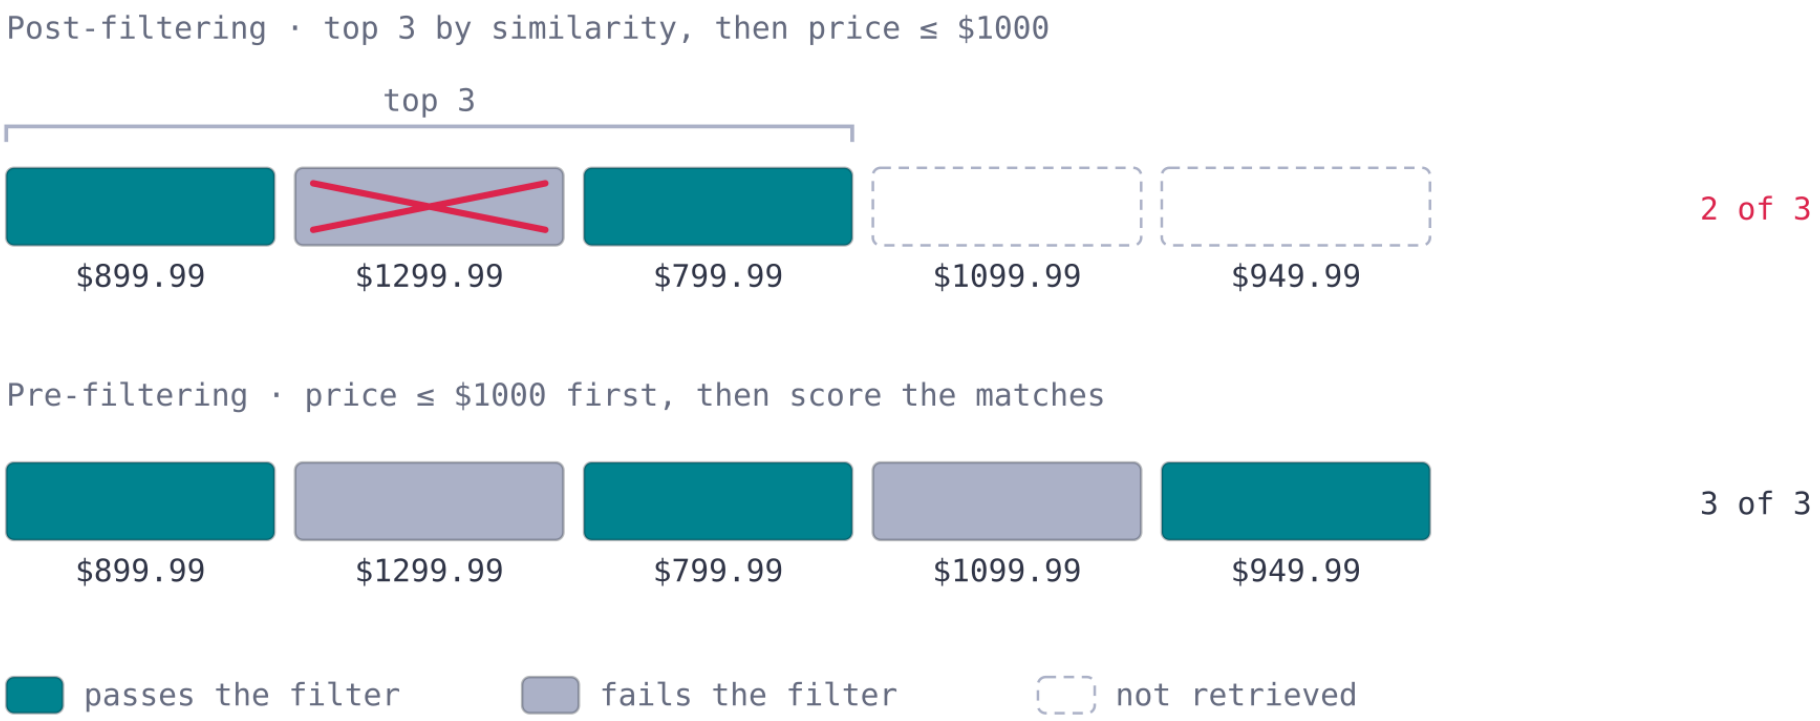
1 + 2 = 3 < 7,5

Пропуск doc 10 и doc 12

Максимумы блоков уже ниже лучшего найденного скора

Ding, Suel · Block-Max WAND · SIGIR 2011

Фильтры



Мало совпадений:
прямой просмотр

Много совпадений:
поиск через граф

Оценка поиска

ANN recall: доля сохранённых exact-соседей

$$\mathrm{Recall}_{\mathrm{ANN}}@k = \frac{|\mathrm{ANN}_k(q) \cap \mathrm{Exact}_k(q)|}{k}$$

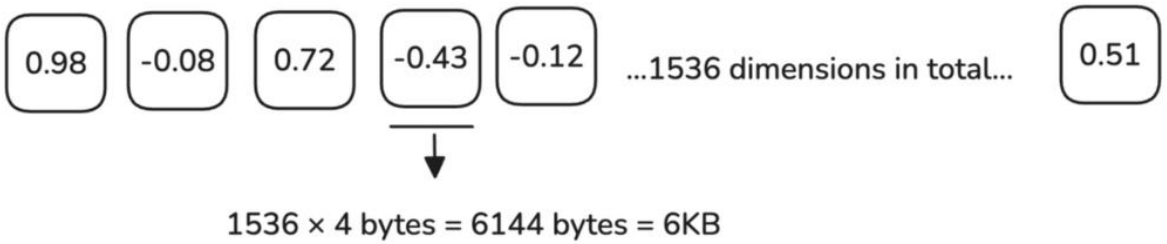
q — запрос; k — размер выдачи
$\mathrm{ANN}_k(q)$ — соседи из ANN-поиска
$\mathrm{Exact}_k(q)$ — точные ближайшие соседи
$|\cap|$ — число общих соседей

Индекс	**Когда выбирать**	**Цена**
Exact scan	После фильтра осталось мало точек	Сканируем все оставшиеся векторы
HNSW	Большой dense-корпус	Память графа и приближённая выдача
Inverted + WAND	Sparse-векторы Мало терминов в запросе	Частые слова удлиняют списки кандидатов

Квантизация

Память и стоимость сравнения

Память индекса



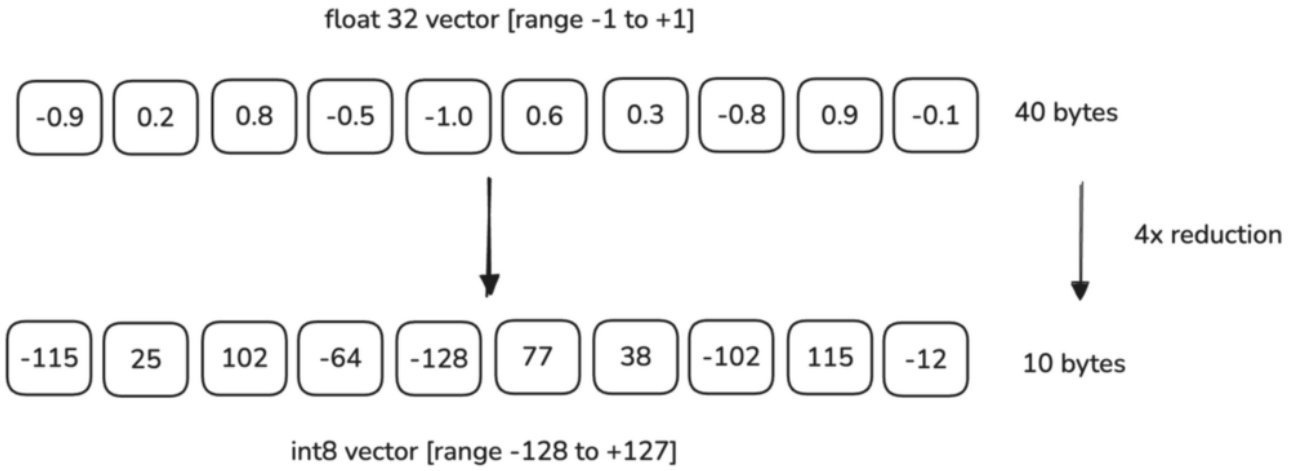
Память под координаты N векторов

$$M_{\text{vectors}} = \frac{NDb}{8}$$

Mvectors — размер массива координат, байт
N — число векторов
D — размерность каждого вектора
b — число бит на координату
8 — перевод битов в байты

Qdrant · What is Vector Quantization? · Qdrant · Storage

Scalar Quantization (SQ)



Кодирование координаты: 8 бит

$$c_i = \text{round}\left(\frac{x_i - a}{\Delta}\right)$$

x_i — исходная координата i
a — смещение (на рисунке a = 0)
Δ — шаг квантования
c_i — целый код; round — округление

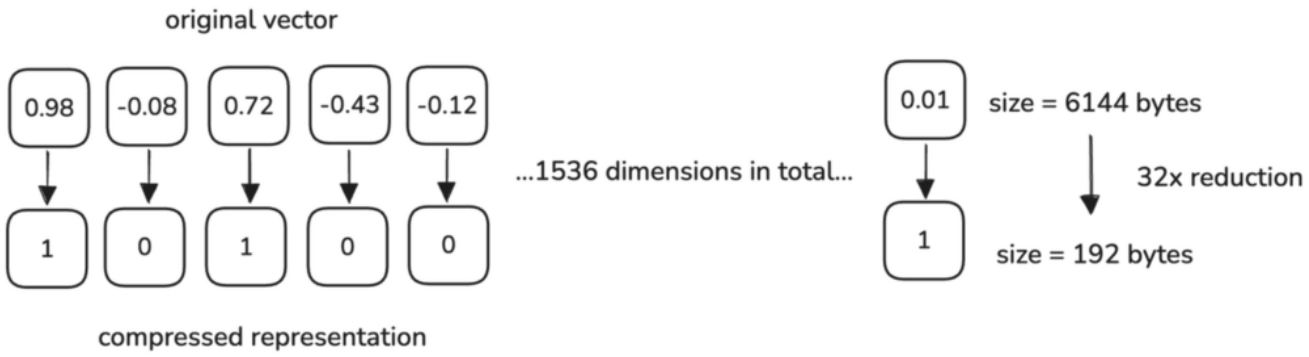
Восстановление координаты

$$x_i' = a + \Delta c_i$$

x_i' — приближённое значение x_i
$a + \Delta c_i$ — центр выбранного уровня

Qdrant · What is Vector Quantization? · Qdrant · Quantization

Binary Quantization (BQ)



Битовый код знака координаты

$$b_i = \mathbf{1}_{\{x_i \geq 0\}}$$

x_i — координата i исходного вектора
$b_i = 1$ при $x_i \geq 0$, иначе $b_i = 0$
1{…} — индикатор истинного условия

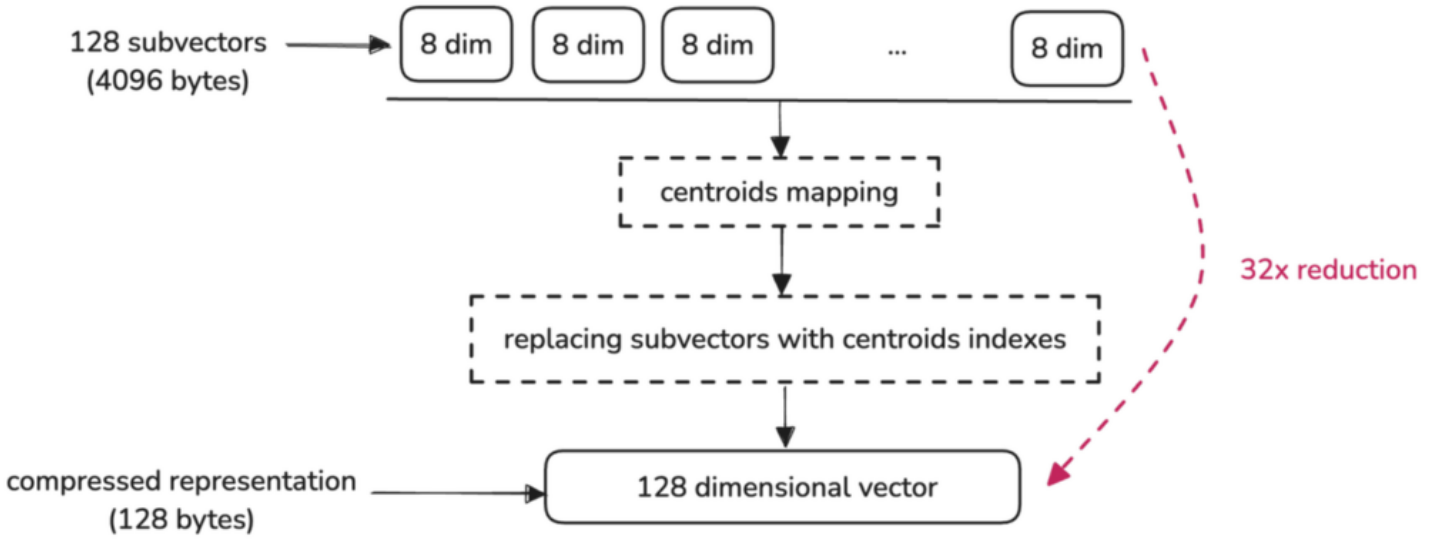
Расстояние Хэмминга кодов

$$d_H = \text{popcount}(b_q \oplus b_d)$$

bq, bd — битовые коды запроса и документа
$\oplus$ — XOR; popcount — число единичных битов
dH — число несовпавших битов

Qdrant · What is Vector Quantization? · Qdrant · Quantization

Product Quantization (PQ)



Ближайший центроид блока j

$$\ell_j^* = \underset{\ell}{\operatorname{argmin}} \|x^{(j)} - \mu_{j\ell}\|^2$$

$x^{(j)}$ — блок j исходного вектора
$\mu_j\ell$ — центроид ℓ в кодовой книге блока j
ℓ^*_j — индекс ближайшего центроида; $\|\cdot\|$ — L2-норма

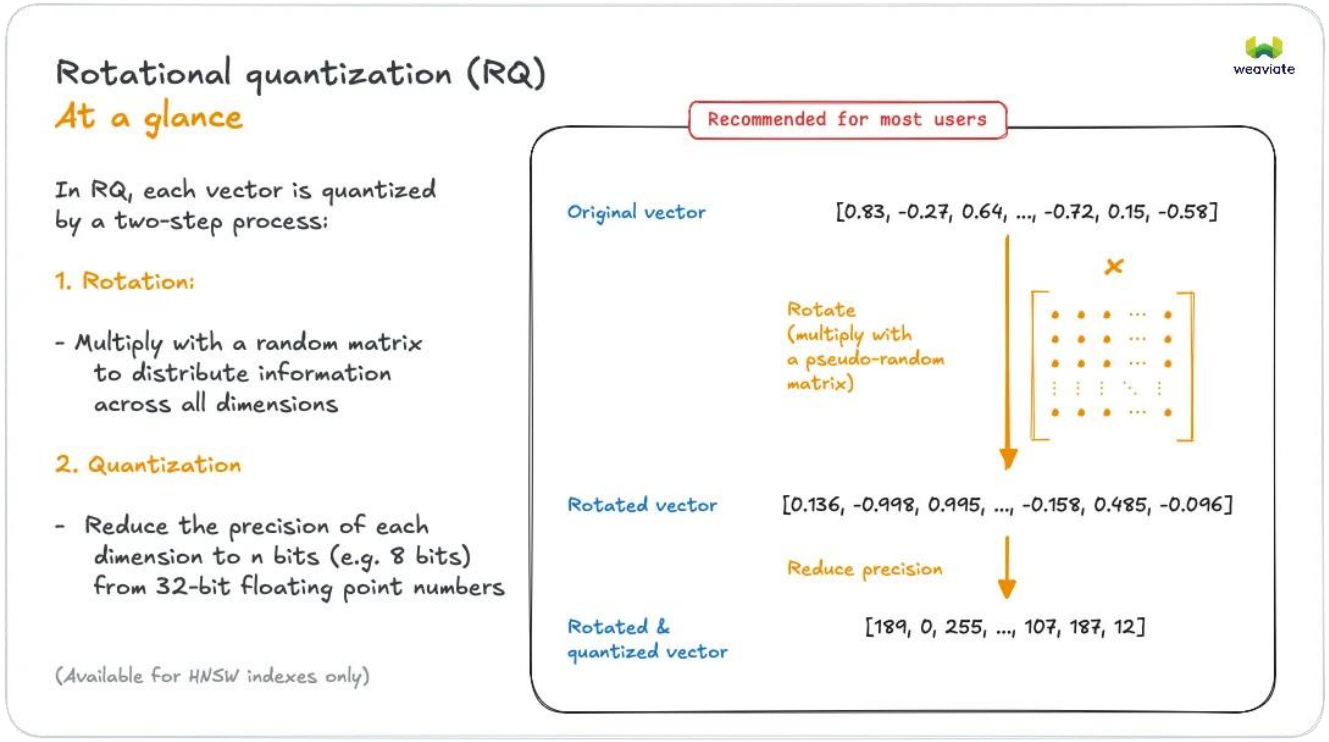
Размер кода одного вектора

$$\text{size} = m\log_2 K \text{ bits}$$

m — число блоков
K — число центроидов в каждом блоке
size — число бит на вектор

Qdrant · What is Vector Quantization?

Rotational Quantization (RQ)



Ортогональный поворот

$$y = Rx$$

x — исходный вектор; y — повёрнутый
R — ортогональная матрица вращения

Сохранение скалярного произведения

$$\langle Rq, Rx \rangle = \langle q, x \rangle$$

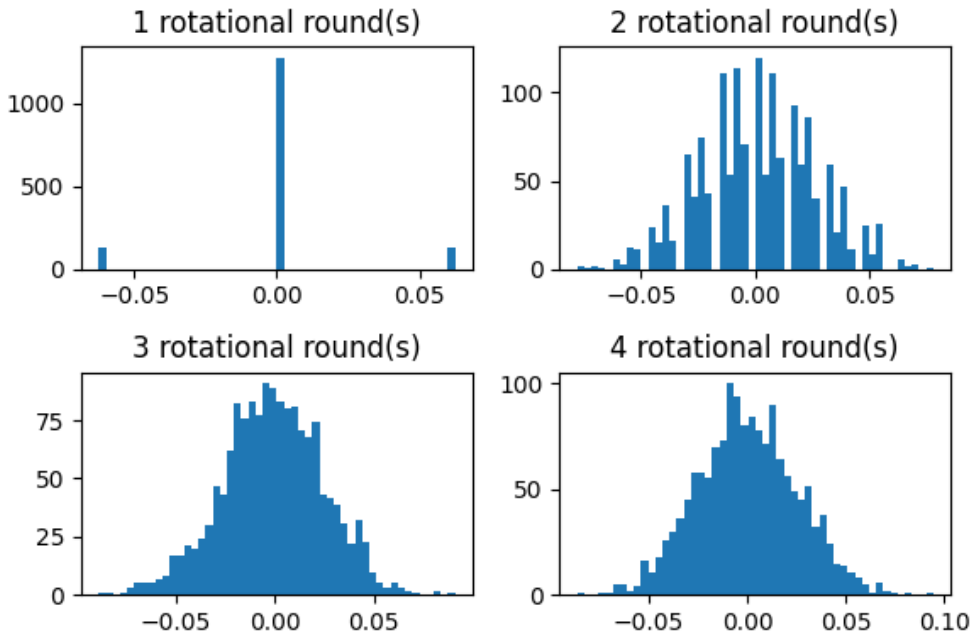
q — вектор запроса
$\langle \cdot, \cdot \rangle$ — скалярное произведение

Код после квантования

$$\text{code} = Q(Rx)$$

Q — скалярный квантователь
code — компактный код вектора x

TurboQuant



Вращение исходного вектора

$$y = Rx$$

x — вектор; R — матрица вращения
y — повёрнутый вектор; i — координата

Выбор ближайшего уровня

$$j^* = \underset{j}{\operatorname{argmin}} |y_i - c_j|$$

c_j — предвычисленный уровень j
j* — индекс ближайшего уровня к y_i

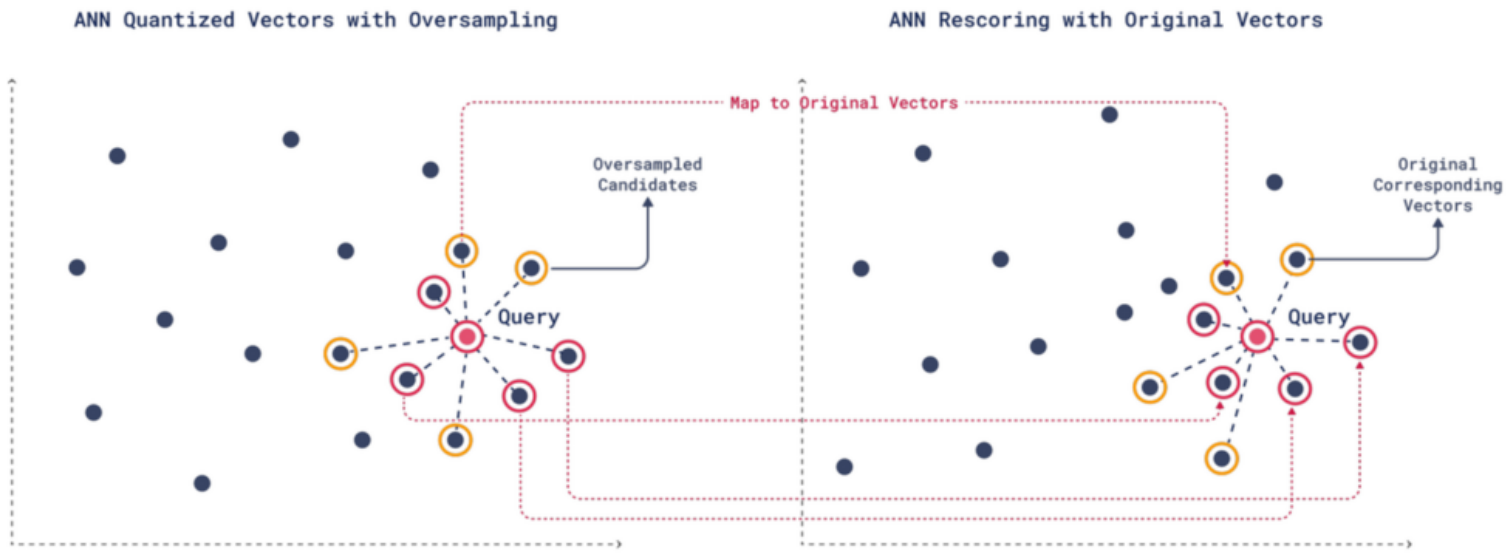
Восстановление координаты

$$Q(y_i) = c_{j^*}$$

Q — скалярный квантователь
$Q(y_i)$ — приближённое значение y_i

Zandieh et al. · TurboQuant · Weaviate · Rotation distributions

Rescoring

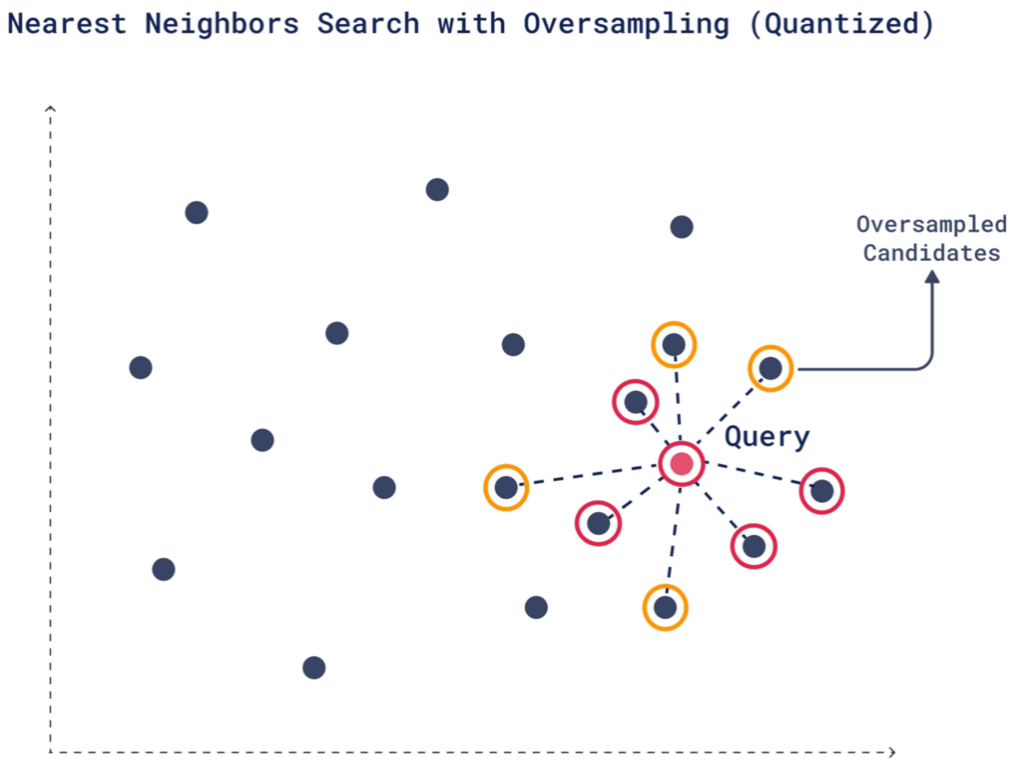


Первый проход по кодам

Точный скор по исходным векторам

Qdrant · What is Vector Quantization? · Qdrant · Quantization

Oversampling



Размер пула для rescoring

$$k' = \lceil \rho k \rceil$$

k — сколько результатов вернуть
ρ — коэффициент oversampling
k′ — число кандидатов для rescoring
⌈·⌉ — округление вверх

Расчёт числа кандидатов

$$k = 20, \rho = 4$$
$$k' = 80$$

Возвращаем 20 результатов после пересчёта скоров 80 кандидатов.

Qdrant · What is Vector Quantization? · Qdrant · Quantization

Выбор квантизации

Метод	Код / сжатие	Когда выбирать	Цена / слабое место
SQ · 8 бит	1536 B / 4×	Умеренное сжатие Быстрый int8 dot product	Выбросы расходуют диапазон координат
BQ · 1 бит	192 B / 32×	Большой D Дешёвый Hamming	Больше кандидатов на rescoring
PQ · 192 блока	192 B / 32×	Жёсткий лимит RAM Есть выборка для обучения	k-means при построении LUT на каждый запрос
RQ · 8 бит	≈1536 B / 4×	Выбросы и разный масштаб по осям	Вращение каждого запроса
TurboQuant **4 бита**	≈768 B / 8×	Мало бит, новые данные без обучения PQ-книг	Вращение и работа с упакованными кодами

D = 1536. FP32: 6144 B. PQ: K = 256. Размеры кодов без графа и originals.

Qdrant · Quantization · Christiani · Weaviate RQ

Лабораторная работа

- Развернуть векторную базу (например https://qdrant.tech/)
- Выбрать датасет (например https://huggingface.co/datasets/mteb/fiqa) и инициализировать коллекцию
- Векторизовать семантической (например вашей обученной) и лексической (например https://qdrant.tech/documentation/edge/edge-bm25/) моделями документы и загрузить их в коллекцию
- Настроить приемлемые скорость и качество поиска, подобрав их под вашу конфигурацию машины (для старта можно взять начальные параметры)
- Замерить качество гибридного поиска с шагом альфа 0.1 (нет необходимости производить множество запросов с разными альфа, можно реализовать фьюжн и ручной расчет вне вбд)